

FOG Detection and Prediction

Fuser Alessandro

7 settembre 2017

Indice

1	Future Learning for Detection and Prediction of Freezing of Gait in Parkinson’s Disease[1]	2
1.1	Sommario	2
1.2	Articolo	2
1.3	Conclusioni	4
2	Wearable assistant for Parkinson’s disease patients with the freezing of gait symptom[2]	4
2.1	Sommario	4
2.2	Articolo	5

1 Future Learning for Detection and Prediction of Freezing of Gait in Parkinson's Disease[1]

1.1 Sommario

In questo paper, vengono prima confrontati approcci di riconoscimento di feature basati sul dominio del tempo e feature statistiche con uno non supervisionato basato sull'analisi delle componenti principali, con il secondo che migliora il Freezing Index. Poi si analizza il problema della predizione del Freezing Of Gait (FoG), identificando dei pattern che avvengono prima degli episodi di FoG basandosi solo su dati provenienti da sensori di movimento. Si verrà a scoprire che le performance della predizione del FoG è altamente paziente dipendente.

1.2 Articolo

Ci sono alcune proprietà specifiche che differenziano i dati durante gli episodi di FoG rispetto alla normale camminata (es. l'energia del segnale della camminata è più spesso sulla banda 3-8Hz) ed, inoltre, si ha un caratteristico cambiamento nel modo di camminare prima di un episodio di FoG. Ma solo grazie a questi non possiamo essere certi di prevedere un episodio, anche perché il deterioramento della normale camminata può essere espressa in vari modi e varia da paziente a paziente. Formuliamo dunque il problema della **Identificazione del FoG** come un problema di classificazione a due classi: FoG contro normale camminata. Il problema della **Previsione del FoG**, invece, lo classifichiamo come un problema a tre classi, aggiungendo alle due precedenti una classe chiamata pre-FoG, dove faremo riconoscimento di tutte quelle caratteristiche specifiche che contraddistinguono il possibile presentarsi di un episodio di FoG. La durata di questo pre-FoG può essere variabile e può essere ricavato dallo studio dei segmenti di dati prima di un episodio di FoG (quando viene riconosciuto). Gli approcci di estrazione delle feature sono i seguenti:

1. Feature basate sulla frequenza, quindi Freezing Index (FI) ed energia totale nella banda di frequenza 0.5-8Hz;
2. Feature nel dominio del tempo e statistiche;
3. Apprendimento delle feature non supervisionato, ossia estrazione delle informazioni dai dati grezzi, senza basarsi su specifici domini.

Il **FI** è definito come il rapporto tra la potenza contenuta nella banda di frequenza di freezing (3-8Hz) e quella della normale camminata (0.5-3Hz), che comporta il solo uso della FFT (Fast Fourier Transform). Vari classificatori sono stati usati per il problema a due classi, come Alberi di Decisione, Alberi/Foreste Random, Naive Bayes, basati su regole o su threshold. Invece

di usare esplicite conoscenze per selezionare specifiche features, si possono estrarre quelle più caratteristiche tramite l'analisi delle componenti principali. Risultati su dataset di attività pubbliche di riconoscimento mostrano che l'apprendimento di feature nel metodo non supervisionato è molto più discriminativo dello state dell'arte basato sui precedenti approcci proposti (basati su tempo o frequenza). Per cui si propone di usare questo metodo per l'identificazione e la previsione di episodi di FoG, poichè le proprietà dei segnali di FoG e pre-FoG sono dipendenti dal soggetto e difficili da modellare. Il processo generale del **processamento e classificazione dei segnali** è il seguente: i segnali sono campionati e divisi in finestra con sovrapposizione parziale; per ogni finestra, le features vengono estratte ed i vettori risultati sono classificati in accordo con un modello già "allenato". Per questo lavoro, la lunghezza della finestra è di 1s (64 campioni) con una sovrapposizione di 0.25s(16 campioni), il classificatore usato è un albero di decisione per il suo basso bisogno di computazione. Ci siamo focalizzati nella selezione delle feature appropriate per la identificazione e predizione del FoG, quindi *l'ottimizzazione dei parametri di classificazione è fuori dai nostri scopi*. Nella fase di training del nostro sistema, abbiamo usato una classificazione delle feature basato sulla Mutua Informazione (MI), per trovare quelle più determinanti nel dominio del tempo e della frequenza (N_F). Sono stati scelti tre gruppi di feature:

1. FI e la somma delle energie delle bande di frequenza;
2. Feature nel dominio del tempo e statistiche, negli assi degli accelerometri o sui sensori;
3. Per imparare la struttura implicita dei dati, ogni finestra di 64 campioni per i tre accelerometri è riarrangiata in un vettore di 192; nella fase di training, un'analisi dei componenti principali (PCA) è applicata sull'intera matrice di dati.

Assumiamo che l'andatura non può entrare in fase di FoG direttamente dalla camminata, ma c'è un deterioramento della stessa che, eventualmente, porta al FoG, rappresentata da un periodo T_{prefog} , il cui valore ottimale dipende dal paziente. Per il problema di detenzione, rimuoviamo dati per un periodo di T_{prefog} prima di ogni evento di FoG nel set di allenamento, che ci porta ad avere un modello di classificazione più preciso per la classi FoG e WALK. Anche se vengono usati tre diversi accelerometri (anca, ginocchio e fondo schiena), ci si focalizza nei dati provenienti dal sensore sull'anca, poichè gli altri sono molto simili. L'inizio di un evento di FoG viene definito come lo stop-parsi nel ritmo dell'andatura, mentre la sua fine è quando questa ricomincia. Le feature più importanti basate su MI sono l'Accelerazione dell'Energia Media (AAE), gli Autovalori della Matrice di covarianza dell'accelerazione sui 3 assi (EVA), l'intervallo, la Varianza, la Radice del Valore Medio e la Deviazione Standard. Le istanze della classe pre-FoG non sono sempre molto

differenti dalle classi WALK o FoG, per cui posso avere confusione, quindi è importante definire bene il T_{prefog} . Inoltre, ci sono delle limitazioni in merito all'assunzione della classe pre-FoG:

- La natura differente degli episodi di FoG, per cui alcuni episodi avvengono senza che ci sia un'andatura prima del FoG, per cui non esiste quel deterioramento che abbiamo assunto;
- La durata del T_{prefog} , che varia da paziente a paziente e da episodio a episodio.

1.3 Conclusioni

In questo lavoro, sono state analizzate le prestazioni di tre differenti approcci di estrazione delle feature per identificare FoG. Features basate nel dominio del tempo e statistiche sono state confrontate con un approccio non supervisionato sull'analisi delle principali componenti, mentre il FI è stato usato come base di riferimento. L'ultimo approccio migliora il FI di 7.1-8.1% in termini di identificazione del FoG. Poi abbiamo cercato di analizzare il problema della predizione del FoG usando una problema a tre classi, assumendo un periodo T_{prefog} di pre-FoG ed abbiamo ottenuto un risultato che dipende altamente dal paziente, con risultati fino al 56% della misura di FI. L'uso delle feature non supervisionate è promettente, poichè catturano importanti variazioni nei dati, senza il bisogno di esperti che selezionino manualmente quelle più importanti. Al fine di migliorare i risultati, altri metodi più complessi non supervisionati per l'apprendimento di feature possono essere testati (PCA che usa kernel non lineari, deep learning) e la durata fissa del T_{prefog} deve essere riconsiderata.

2 Wearable assistant for Parkinson's disease patients with the freezing of gait symptom[2]

2.1 Sommario

Viene usato un sistema wearable che automaticamente riconosce FoG analizzando le componenti in frequenza coinvolte nel movimento. Quando un FoG viene riconosciuto, l'assistente fornisce un segnale auditorio ritmato che stimola il ritorno al camminare del paziente. La sensibilità è del 73.1% e la specificità del 81.6%. Il RAS (Rhythmic Auditory Stimulation) è stato riconosciuto come particolarmente efficace nello sbloccare FoG. Il suono di un metronomo regolare applicato come RAS con una frequenza del 110% rispetto alla normale frequenza di camminata del paziente risulta ottimale nel mantenere la velocità dell'andatura e nel ridurre la variabilità. Il dispositivo wearable che usiamo mira a fornire il RAS solo durante il FoG o per impedirne l'accadimento, quindi include algoritmi per il riconoscimento del FoG online. Questo

manda i dati acquisiti ad un computer tramite una connessione Bluetooth ad una rate di 64Hz per il processo dei dati online. Il freeze viene riconosciuto usando una soglia ed i valori del **FI** oltre questa soglia vengono riconosciuti come FoG.

2.2 Articolo

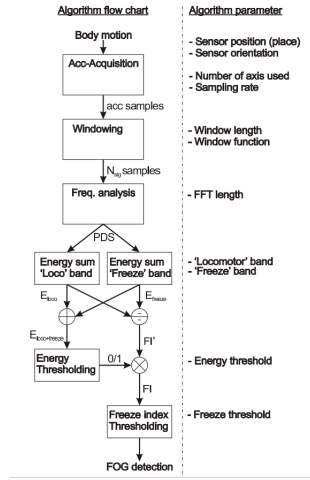


Figura 1: Flow chart che descrive l'algoritmo di detenzione del FoG e tutti i suoi paramentri

quando vengono ottimizzati i parametri in base allo stile di camminata, si riesce ad ottenere una sensibilità dell'86.6% e una specificità dell'92.4%. Durante l'esperimento, anche i migliori risultati sono stati ottenuti dall'uso dell'asse verticale del sensore piazzato sul ginocchio, si è visto che non si perde molta accuratezza anche posizionando i sensori in altre parti del corpo. La latenza dell'algoritmo è dominato dalla lunghezza della finestra di campionamento, che si è dimostrata ottimale quando era settata su 4.5s.

2.3 Conclusioni

I calcoli complessi, come la FFT, che sono usati per il riconoscimento online del FoG, possono essere processati anche da device con poco consumo di potenza e della taglia di un bottone, quindi un dispositivo wearable va benissimo per lo scopo, indipendentemente dal suo posizionamento nel corpo.

Il consiglio è quello di integrare l'algoritmo di detenzione direttamente nel dispositivo.

Riferimenti bibliografici

- [1] Sinziana Mazilu, Alberto Calatroni, Eran Gazit, Daniel Roggen, Jeffrey M.Hausdorff, Gerhard Troster, *Future Learning for Detection and Prediction of Freezing of Gait in Parkinson's Disease*
- [2] Marc Bachlin, Meir Plotnik, Daniel Roggen, Inbal Maidan, Jeffrey M.Hausdorff, Nir Giladi, Gerhard Troster *Wearable assistant for Parkinson's disease patients with the freezing of gait symptom*, 2009