
Università di Verona
Dipartimento di Informatica
Laurea Magistrale in Ingegneria e Scienze Informatiche

**Apprendimento non supervisionato per
l'identificazione di contesti di
Freezing of Gait (FoG)
in pazienti affetti da morbo di Parkinson**

Candidato
Fuser Alessandro

Supervisore
Graziano Pravadelli

Assistente Supervisore
Florenc Demrozi

Sessione di Laurea del 21 Marzo 2018
Anno Accademico 2016/2017

Abstract

Ringraziamenti

Indice

Ringraziamenti	v
1 Introduzione	1
1.1 Contributo della Tesi	1
2 Letteratura	3
3 Conoscenze Preliminari	7
3.1 Freezing Of Gait	7
3.1.1 Le tipologie di Fog	8
3.1.2 Influenza del FoG nella camminata	8
3.2 Machine Learning	9
3.2.1 Cluster Analysis	12
3.2.2 Classificazione	19
3.2.3 Validazione della Classificazione	21
3.3 Riduzione della dimensionalità	22
3.3.1 Analisi Delle Componenti Principali	22
3.3.2 Analisi dei Discriminanti Lineari	24
4 Motivazioni ed obiettivi	27
5 Apprendimento non supervisionato	29
5.1 Dataset	29
5.2 Approccio basato su Feature Statistiche	30
5.2.1 Pre-processamento dei dati	31
5.2.2 Definizione degli intervalli	31
5.2.3 Calcolo delle Feature	31
5.3 Feature Dinamiche	36
5.4 Linear Discriminant Analysis	36
6 Conclusione e Lavori Futuri	37
6.1 Risultati	37
6.2 Lavori Futuri	37

Bibliography

39

Elenco delle tabelle

3.1	Misure di Similarità	14
5.1	Descrizione delle Feature Statistiche	32

Elenco delle figure

3.1	Diversi tipi di Freezing esistenti e loro percentuale di incidenza su un certo gruppo di malati di Parkinson. [Fonte: J.M. Shine et al., 2012]	9
3.2	Quadro concettuale relativo al Freezing of Gait (FoG) riguardante aspetti mentali e motori.	10
3.3	Schema delle tipologie di Machine Learning	11
3.4	Esempio di Workflow tramite Machine Learning	12
3.5	Rappresentazione dei dati e dei gruppi ottenuti con la cluster analysis	13
3.6	Esempio di assegnazione dei dati tramite l'algoritmo k-means	15
3.7	Esempio di assegnazione dei dati tramite l'algoritmo k-medoids	16
3.8	Esempio di assegnazione dei dati tramite cluster gerarchico e la sua rappresentazione tramite dendogramma	17
3.9	Schema input-output per una SOM	18
3.10	Rappresentazione dei possibili approcci usando strategie di clustering	19
3.11	Rappresentazione della matrice di confusione per 2 classi	21
3.12	Rappresentazione della matrice di confusione per c classi	22
3.13	Rappresentazione del cambio di dimensionalità tramite PCA	23
3.14	Rappresentazione del cambio di dimensionalità tramite LDA	25
5.1	Schema generale di calcolo delle feature statistiche	33
5.2	Grafico degli intervalli di overlap e secondi della finestra temporale per ogni paziente	34
5.3	Grafico dell'accuratezza per ogni paziente	35
5.4	Grafico della precisione media delle classi per ogni paziente	35
5.5	Grafico della recall media delle classi per ogni paziente	36

Introduzione

La Malattia di Parkinson è una patologia neurodegenerativa che coinvolge in maniera elettiva la capacità di programmare ed eseguire il movimento, senza risparmiare altri aspetti dell'individuo come la sfera cognitiva e comportamentale. Questi aspetti, unitamente al decorso cronico e progressivo della malattia, determinano una compromissione delle attività di vita quotidiana e delle relazioni interpersonali.

Tra i sintomi della malattia di Parkinson, il Freezing of Gait (FOG) può sicuramente essere considerato uno dei più debilitanti. Il Freezing nella malattia di Parkinson, detto anche congelamento o semplicemente blocco motorio, è un'improvvisa, temporanea e involontaria incapacità di iniziare un movimento. È un disturbo che insorge nel corso dell'evoluzione della malattia di cui costituisce un sintomo indipendente e generalmente resistente al trattamento con levodopa. Tale fenomeno si può verificare in ogni momento e i pazienti che lo sperimentano affermano che: *«è come se i piedi rimanessero, per qualche istante, incollati al suolo con la conseguente impossibilità di eseguire il passo successivo»*. In realtà, il Freezing si può verificare anche durante azioni differenti dal cammino come ad esempio l'alzarsi da una sedia o il raccogliere un oggetto. Alcune persone sono più predisposte di altre a subire episodi di congelamento. Tali episodi, si possono verificare sia quando il soggetto è in astinenza da farmaci dopaminergici, in questo caso si parla di "Freezing off", sia quando il soggetto sta assumendo i farmaci, "Freezing on".

1.1 Contributo della Tesi

In questa lavoro di tesi, si è cercato di sviluppare una metodologia non supervisionata, ossia che non abbia bisogno dell'intervento dell'essere umano, per identificare gli episodi di FoG. Questo è un problema molto debilitante per i malati di Parkinson che, allo studio attuale, non ha una soluzione efficace dal punto di vista medico e di cui non si conoscono a fondo le cause.

Per sviluppare tale metodologia, è stato utilizzato un dataset in cui sono

presenti 10 pazienti, tutti affetti dal morbo di Parkinson, ed 8 di loro presentano episodi di FoG. I contesti di FoG sono stati identificati dal dottore tramite l'utilizzo di videoregistrazioni ed i dati sono stati raccolti attraverso 3 accelerometri, posizionati sulla caviglia, sul ginocchio e sulla zona lombare del paziente.

Il primo passo è stato quello di dividere in finestre temporali e di filtrare i dati ottenuti dagli accelerometri, al fine di calcolare sulle stesse delle grandezze su cui sono state applicate gli algoritmi di clustering, al fine di dividere in automatico le occorrenze di FoG, di pre-FoG e di camminata normale. E' stato poi condotto uno studio sulla possibilità di utilizzare un solo accelerometro invece di 3 contemporaneamente. Poichè il dividere in finestre temporali fissate poteva portare all'eliminazione di contesti interessati, i.e. episodi di FoG, è stato condotto uno studio anche su finestre temporali dinamiche, ossia in base all'etichettatura data dal dottore nel dataset. Infine, è stato usato un approccio di discriminazione delle caratteristiche per dividere maggiormente i vari contesti.

Il resto della tesi è organizzata nel modo seguente: nel **Capitolo 2** si presentano i risultati dei principali lavori svolti sul FoG; nel **Capitolo 3** si presentano a livello teorico le problematiche del FoG e gli strumenti su cui si basa il lavoro svolto; nel **Capitolo 4** si presenta qual'è l'obiettivo finale del lavoro che viene svolto; nel **Capitolo 5** si presenta il lavoro svolto; nel **Capitolo ??** si fornisce l'implementazione software del lavoro; nel **Capitolo 6** si riassume i risultati ottenuti e si presentano possibili miglioramenti al lavoro svolto.

Letteratura

Il problema del FOG è stato analizzato tramite una grande varietà di sistemi e sensori. Alcuni di questi, però, non sono utilizzabili durante la vita quotidiana dei pazienti poiché posso essere disponibili solo in ambienti di laboratorio. Esempi di questi sistemi sono le piattaforme di pressione[19], le quali sono non portatili, l'elettromiografia (EMG)[6], l'elettroencefalogramma (EEG)[22] o la conduttanza della pelle[26], il quale comporta il pizzamento di elettrodi sulla pelle in aggiunta ad sistema di rilevamento per raccogliere i dati. Altri sistemi invasivi sono i goniometri a ginocchio[1] o sistemi che fanno uso di camere e video, i quali hanno una bassa tolleranza del paziente in un'ambiente che non sia di laboratorio[1, 2, 5]. Quindi, dato che il monitoraggio del PD dovrebbe essere deambulatorio e durare diverse ore al fine di ricavare utili informazioni cliniche[9, 4], la maggior parte dei lavori si è basata su sistemi non invasivi come i dispositivi indossabili basati su circuiti microelettromeccanici (MEMS).

Nel 2003, Han et al. hanno usato MEMS basati su sistemi inerziali, come gli accelerometri, per esplorare le caratteristiche collegate agli episodi di FoG. Hanno trovato che la frequenza di risposta nei pazienti che indossavano gli accelerometri nella caviglia era intorno ai 6-8 Hz[18]. Nel 2008, Moore et al. hanno proposto una metodologia per identificare FoG con un'accelerometro posizionato nella caviglia nella quale hanno descritto il Freezing Index (FI), ossia il quoziente del rapporto della densità spettrale di potenza (PSD) tra 3 ed 8 Hz, chiamata Freezing Band (FB), con la PSD tra 0.5 e 3 Hz, denominata Walking Band (WB)[21]. Quando il FI supera una certa soglia (Freezing Threshold (FTH)), si considera che si sia verificato un episodio di FoG. A causa della presenza dei falsi positivi (FP) quando il paziente è a riposo, Bachlin et al. hanno introdotto il concetto di Power Index (PI), definito come la somma della WB e FB, il quale viene comparato con la Power Threshold (PTH) al fine di stabilire se c'era una quantità rilevante di movimento nel momento in cui il FI era alto, ossia oltre la soglia[21]. PI indica la quantità di movimento, perciò situazioni nelle quali il paziente non si stesse muovendo volontariamente sono state eliminate. In quest'ultima versione dell'algoritmo, quindi, un episodio di FoG è occorso se $FI > FTH$ e $PI > PTH$. Questo

metodo è il più avanzato nella detenzione di FoG dato il suo scarso costo computazionale e le sue buone performance[13].

L'algoritmo MBFA è stato ampiamente utilizzato nell'analisi del FoG, anche se di solito in condizioni di laboratorio e molto spesso con pochi pazienti. Jovanov et al. hanno implementato un algoritmo real time, anche se un solo volontario è stato usato per testare l'algoritmo. Inoltre, nessun risultato su sensitività e specificità è stato riportato[13]. Zabaleta et al. hanno analizzato il FoG per mezzo di accelerometri a tre assi e giroscopi a due assi in differenti locazioni degli arti inferiori. La caratteristica principale ad essere stata analizzata è il FI in congiunzione con i cambiamenti della densità spettrale di potenza. Sono stati capaci di identificare correttamente l'82.7% degli episodi di FoG con i sensori inerziali posizionati su entrambe le caviglie, anche se in soli 2 pazienti[15].

Più recentemente, Niazmand et al. (2011) hanno presentato il Mimed-Pants[20], pantaloni da jogging lavabili con 5 accelerometri integrati. Hanno usato MBFA per identificare FoG, ottenendo un 88.3% in sensitività e 85.3% in specificità con 6 pazienti in brevi e controllati test focalizzati nell'indurre FoG senza tenere conto dei FP. Nel 2012, Zhao et al.[30] hanno sviluppato un algoritmo embedded basato sull'approccio MBFA all'interno del sistema Mimed-Pants ottenendo un 81% in sensitività con 8 pazienti usando dei test simili ai precedenti. Più recentemente, Mazilu et al. hanno proposto un nuovo algoritmo online usando 3 accelerometri ed comparando diversi classificatori di machine learning che sfruttavano le caratteristiche del MBFA, aggiungendone di nuovo, in 10 pazienti[27]. I risultati ottenuti sono stati migliori del 95% per specificità e sensitività con differenti classificatori. Questi test, però, sono stati condotti in situazioni di controllo ed, inoltre, la metodologia di validazione sovrastimava le prestazioni delle misure poiché i classificatori erano allenati, iterativamente, con tutte le finestre del segnale disponibili da un paziente escludendone una, la quale veniva usata per ottenere le prestazioni citate. Inoltre, le sequenze di allenamento e di test erano molto simili, il che è molto diverso da normali situazioni. Quindi, ci si aspetta che le riportate specificità e sensitività calino drasticamente in situazioni non controllate.

Nel 2013, Moore et al. hanno pubblicato il più recente lavoro focalizzato sul MBA. In questo, hanno confrontato differenti configurazioni applicando lo stesso algoritmo in 25 pazienti, dei quali 20 hanno avuto episodi di FoG. Diverse finestre di segnale, posizionamento dei sensori e valori per PTH e FTH sono stati valutati al fine di trovare le condizioni ottimali. I risultati migliori sono stati ottenuti con le finestre di segnale più lunghe, anche se con queste Moore et al. hanno riportato una rilevante perdita di sensitività negli episodi brevi che, paradossalmente, sono quelli più frequenti nei pazienti affetti da PD[28]. In un test più complesso eseguito precedentemente[29] usando fino a 7 sensori ed un protocollo di test più lungo, sono stati ottenuti una sensitività e specificità sopra al 70%, anche se, in certe configurazioni (finestra di segnale pari a 7.5s e il sistema installato nella zona lombare), sia

per la sensibilità che la specificità hanno raggiunto valori oltre l'80%. In un approccio differente, Tripoli et al. hanno testato diverse configurazioni e locazioni dei sensori al fine di trovare la migliore configurazione[14]. Il lavoro è stato svolto con 5 pazienti ed in condizioni controllate, usando uno specifico protocollo progettato per stimolare il FoG e senza test di FP. In tale lavoro, hanno integrato 2 giroscopi oltre a 6 accelerometri posizionati in posizioni differenti del corpo. Con tutti i sensori indossati, è stata ottenuta un'accuratezza del 96.11%, una specificità del 98.74% e, eseguendo i test su tutti i pazienti tranne uno, una sensibilità dell'81.94%. D'altra parte, con una IMU singola nella zona lombare hanno riportato una sensibilità del 75% ed una specificità del 95%, anche se l'algoritmo non è stato confrontato con nessun altro metodo usato sotto le stesse condizioni.

Mazilu et al.[10] hanno investigato un approccio di apprendimento non supervisionato per costruire un input ottimale per un classificatore ad albero di decisione con il dataset del progetto DAPHNET (10 pazienti PD). Il loro approccio è stato comparato ad un analogo basato su MBFA nel quale il FI e l'energia della banda spettrale tra 0.5 Hz e 8 Hz sono state valutate. L'allenamento ed i test erano dipendenti dall'utilizzatore e sotto condizioni controllate. I risultati superano l'approccio MBFA similare dell'8.1% in termini di punteggio dell'F1. Un altro approccio è stato presentato da Rodriguez et al., i quali hanno proposto un metodo per contestualizzare gli episodi di FoG tramite un algoritmo di riconoscimento dell'attività, il quale rifiutava i FP quando il paziente era seduto o eseguiva attività quali disegnare o digitare in un laptop. La specificità è stata aumentata in media del 5%, arrivando anche ad un 11.9% in certi casi[10]. Il metodo che aggiungeva la contestualizzazione, però, non ha contribuito a migliorare la sensibilità. Altri studi hanno la variabilità della camminata tra un episodio di FoG e condizioni normal. Anche se i risultati sono interessanti, hanno fallito nell'includere i falsi positivi ed un'affidabile classificazione non è stata eseguita[8, 3]. Un paper recente di Zach et al. presenta una nuova metodologia per suscitare FoG in condizioni di laboratorio controllate, le quali sono state valutate con l'algoritmo MBFA ottenendo una sensibilità del 75% ed una specificità del 76%[16].

Infine, Alrichs et al., all'interno del progetto REMPARK[25], usano una Support Vector Machines (SVM) per rilevare episodi di FoG in 8 pazienti con PD in ambiente casalingo. Il metodo include test in differenti test motori usando un singolo accelerometro nella zona lombare, raggiungendo un'accuratezza del 90%. La specificità, però, è stata calcolata solo non pazienti non FoG, il che può portare a predizioni non affidabili in quanto il modello non è stato testato con pazienti PD con FoG, i quali hanno movimenti molto diversi dai pazienti che non soffrono di FoG. Inoltre, la valutazione è stata eseguita su finestre di un minuto, tempo che è considerato troppo lungo per un'implementazione online[7]. Sempre all'interno del progetto REMPARK, Rodriguez et al. hanno presentato un lavoro che utilizza un algoritmo per

rilevare FoG tramite un approccio di machine learning basato su SVM ed un singolo accelerometro a 3 assi indossato nella zona lombare[11]. Il metodo è stato valutato su 21 pazienti affetti da PD in ambienti casalinghi sotto due condizioni: un modello generico testato su tutti i pazienti tranne uno ed un secondo modello personalizzato sull'utente che usa parte del dataset del paziente stesso. I risultati mostrano un significativo vantaggio del modello personalizzato rispetto a quello generico, portando ad un miglioramento in media, sia della sensibilità che della specificità, del 7.2%. Inoltre, l'approccio adottato è stato comparato con i metodi più utilizzati per la detenzione del FoG basati sull'algoritmo MBFA. I risultati del metodo generico mostrano un miglioramento in media dell'11.2% rispetto a metodi MBFA generici, mentre quello personalizzato porta ad un miglioramento del 10% rispetto ad altri metodi specifici sul paziente.

Conoscenze Preliminari

3.1 Freezing Of Gait

È stato dimostrato che il fenomeno del Freezing nella malattia di Parkinson è spesso collegato alle frequenti cadute a cui i soggetti malati vanno incontro. Le cadute nel Parkinson si verificano più spesso quando il soggetto si gira o cambia direzione e sono frequentemente legate a diversi episodi di Freezing. Non tutti i malati di Parkinson subiscono il fenomeno del Freezing, ma si pensa che coloro che lo provano abbiano una più alta probabilità di cadere a terra. L'imprevedibilità del Freezing, accompagnata dallo sforzo inutile a cui il soggetto si sottopone per cercare di muoversi in avanti, possono causare perdita di equilibrio e quindi cadute.

Nel tentativo di superare questo stato di forzata immobilità, i pazienti, talora con un aiuto esterno, cercano di mettere in atto adeguate strategie che si avvalgono di stimoli sensoriali di diversa natura (tattili, visivi oppure uditivi e verbali). Alcune tecniche di tipo motorio o sensoriale possono aiutare i pazienti a convivere con il problema del Freezing. Ad esempio, un paziente incapace di iniziare il primo passo potrebbe riuscire a superare il blocco motorio adottando una delle seguenti strategie:

- fare un passo in direzione di un bersaglio;
- fare un passo per superare un bastone posto sul pavimento;
- fare il primo passo marciando come un soldato.

L'idea che sta alla base di tali stratagemmi è mettere in atto un programma motorio volontario che sostituisca il programma motorio automatico malfunzionante nei malati di malattia di Parkinson. Episodi frequenti di Freezing possono avere pericolose conseguenze sia sullo stato fisico sia su quello psicologico del malato e compromettono ampiamente la qualità della vita di chi ne soffre privandolo spesso dalla propria indipendenza.

3.1.1 Le tipologie di Fog

Il FoG è un episodio transitorio che usualmente dura pochi secondi e di cui ancora non si conosce la patofisiologia, ossia la causa scatenante, ma è stato dimostrato che esistono più sottotipi di Freezing, che si differenziano per l'evento scatenante il fenomeno:

- necessità del paziente di girare su sè stesso per cambiare direzione (esitazione legata alla svolta);
- attraversamento di spazi stretti, come una porta od un corridoio;
- inizio del movimento di camminata;
- regolazione dei passi in prossimità della destinazione (come ad esempio una sedia su cui sedersi);
- stress, come lo squillo di un telefono o campanello o quando la porta dell'ascensore si apre.

Come la malattia progredisce, però, il FoG può apparire spontaneamente anche in uno spazio aperto, evidenziando così l'aspetto imprevedibile di questo fenomeno. Inoltre, fonti di distrazione, che possono distogliere l'attenzione del soggetto dal cammino, o il compimento contemporaneo di più azioni (dual-tasking) possono aumentare la probabilità che si verifichi un episodio di Freezing.

Dallo studio di Schaafsma et al.[12] emerge che gli episodi di Freezing possono anche essere suddivisi in ulteriori tre sottotipi andando ad osservare i movimenti delle gambe dei pazienti e applicando la classificazione di Thompson e Marsden (1995):

1. FoG associato a passi molto piccoli e strascicati con il minimo movimento in avanti (trascinamento con piccoli passi);
2. FoG caratterizzato da tremore alle gambe, ma nessun movimento in avanti efficace (tremore da fermo);
3. FoG caratterizzato da acinesia completa, vale a dire, nessun movimento osservabile delle gambe.

La necessità di dividere il FoG in sottogruppi dipende dal fatto che questi ultimi potrebbero avere origine differente e quindi essere provocati da cause separate.

3.1.2 Influenza del FoG nella camminata

Il Freezing of Gait influenza il pattern del cammino sia all'inizio della deambulazione sia a regime incrementando o diminuendo in modo evidente i valori




Figura 3.1: Diversi tipi di Freezing esistenti e loro percentuale di incidenza su un certo gruppo di malati di Parkinson. [Fonte: J.M. Shine et al., 2012]

dei parametri sopra riportati. Ad esempio, nei parkinsoniani che manifestano frequenti fenomeni di Freezing, la variabilità della durata del passo risulta maggiore e la lunghezza del passo minore rispetto alle situazioni in cui il Freezing è assente. Inoltre, la velocità e la lunghezza dei primi tre passi sono significativamente inferiori nei pazienti con malattia di Parkinson e con Freezing rispetto ai soggetti sani. Anche se il Freezing è tipicamente considerato un problema motorio, il fatto che spesso compaia quando il paziente si trova in spazi ristretti, suggerisce che la percezione dello spazio contribuisce in larga misura a scatenare il sintomo[24]. Inoltre, i pazienti con Freezing hanno velocità media del cammino minore rispetto a pazienti sani e subiscono una riduzione ulteriore della velocità nel momento in cui si trovano a dover attraversare una porta o uno spazio stretto. Depressione e ansia possono comportare un carico cronico sulla salute mentale, e la depressione è associata con i cambiamenti di andatura, tra cui una maggiore variabilità passo-a-passo. Il Dual-Tasking, l'ansia e la depressione possono incrementare la variabilità del passo, la di-sincronizzazione di gamba destra e sinistra e l'asimmetria nei pazienti con Parkinson riducendo così la soglia per il FoG.

3.2 Machine Learning

Il Machine Learning (ML) è un settore dell'Intelligenza Artificiale che si occupa di studiare le modalità in cui un computer può imparare (o migliorare le

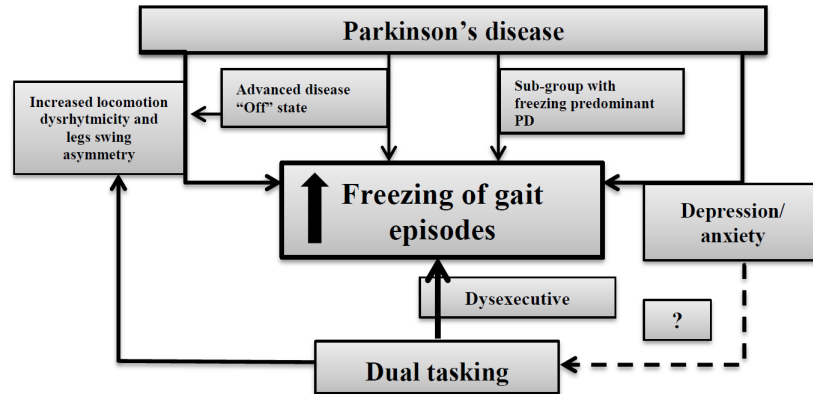


Figura 3.2: Quadro concettuale relativo al Freezing of Gait (FoG) riguardante aspetti mentali e motori.

sue prestazioni) dai dati[17]. Un'ampia area di ricerca tratta l'apprendimento automatico di sequenze complesse di dati e compiere decisioni intelligenti su di essi. Per esempio, un tipico problema di ML è quello di programmare un computer in modo tale che possa automaticamente riconoscere codici postali scritti a mano nelle lettere, dopo aver fatto allenare il computer stesso su dei dati. Gli algoritmi di apprendimento automatico sono tradizionalmente divisi in tre principali tipologie:

- **Apprendimento supervisionato:** quando l'utente fornisce esempi (e controesempi) di quello che si deve apprendere. E' il problema più studiato nel machine learning. Esso si pone l'obiettivo di prevedere, dato un elemento di cui si conoscono un insieme di parametri (features), il valore di un diverso parametro di output relativo all'elemento stesso;
- **Apprendimento non supervisionato:** parte da osservazioni non preclassificate;
- **Apprendimento con rinforzo:** tecnica di programmazione che si basa sul presupposto che l'algoritmo possa ricevere stimoli dall'esterno a seconda delle scelte fatte.

Il problema del ML è definito a partire da un universo di elementi: ciascun elemento x è descritto dai valori assunti da un insieme di features considerate come input del problema. Ad ogni x è associato un valore y di output (o target). A partire dalla conoscenza di un insieme T di elementi (denominato training set) in cui ogni elemento è descritto da una coppia (x_i, y_i) , con x_i = vettore dei valori delle d features $x_{i1}, x_{i2}, \dots, x_{id}$ e y_i = valore di output, si vuole derivare un modello delle relazioni sconosciute tra features e valori di output, che, dato un nuovo elemento x , consenta di predire il corrispondente

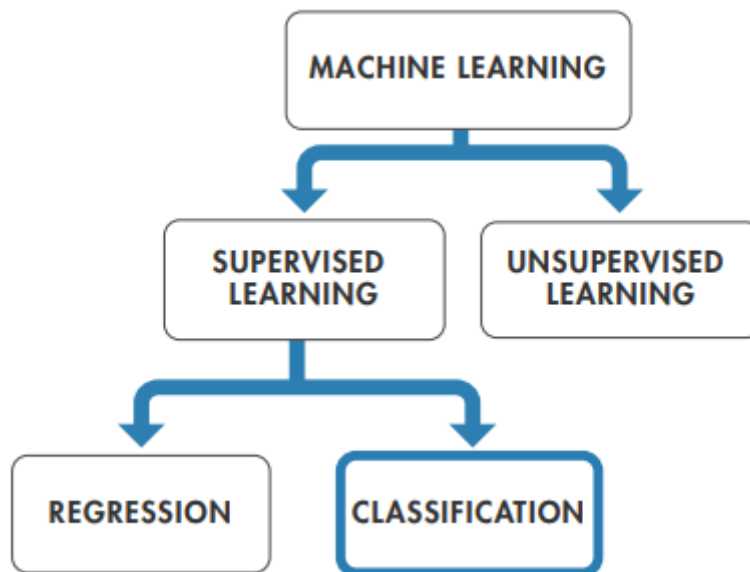


Figura 3.3: Schema delle tipologie di Machine Learning

valore di output y . Lo scopo dell'apprendimento supervisionato è di costruire un **modello di predizioni** basato su evidenze in presenza di incertezze. Un algoritmo di apprendimento supervisionato prende un insieme conosciuto di dati di input e di risposte ai dati (output) ed allena un modello al fine di generare predizioni ragionevoli a nuovi dati di input. Esistono due tecniche per questo approccio:

- **Classificazione:** tecnica per predire risposte discrete, classificando i dati di input in categorie;
- **Regression:** tecnica per predire risposte continue.

L'apprendimento non supervisionato, invece, trova pattern nascosti o strutture intrinseche nei dati. Tale tecnica è usata per identificare inferenze da un dataset consistente di dati di input senza classi già definite. Il clustering è l'approccio più diffuso di tale tecnica ed è utilizzato per trovare gruppi nei dati.

L'approccio che si usa con il ML è differente da problema a problema, per cui non sempre si ha a priori un procedimento fissato da seguire, ma piuttosto si procede a tentativi ed errori, molte volte provando diverse idee ed approcci che appartengono a tale contesto. Per questo è importante definire uno schema di lavoro generale ed evidenziare alcuni punti di decisione chiave lungo il percorso:

1. Accesso e caricamento dei dati: questi possono essere di tutte le forme e i tipi, incompleti o mescolati;

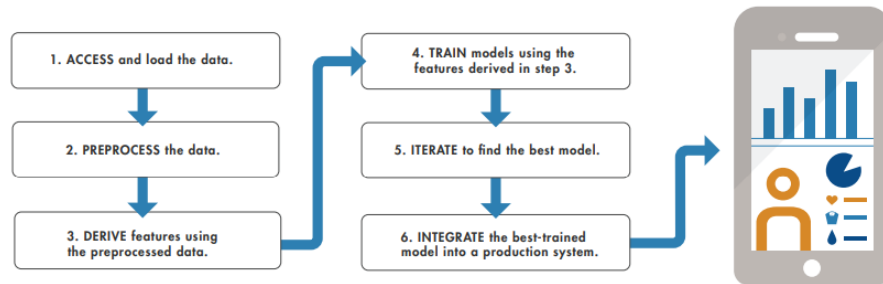


Figura 3.4: Esempio di Workflow tramite Machine Learning

2. Pre-processamento dei dati: applicazione di filtri o ri-campionamento;
3. Derivazione di feature: trovare caratteristiche peculiari a partire dai dati;
4. Allenamento del modello di ML: può essere un procedimento lungo, poichè dipende da molti parametri;
5. Integrazione del modello in un sistema di produzione.

La scelta della modalità supervised o unsupervised si basa sui vantaggi e svantaggi di entrambe: la modalità supervised riesce a predire la giusta classe per le istanze appartenenti al test set ma richiede una consistente quantità di istanze annotate e questo può rappresentare un processo costoso se effettuato manualmente. La modalità unsupervised tipica del clustering, invece, ha il vantaggio di non richiedere un training già annotato (situazione particolarmente frequente quando si ricorre al ML) ma difficilmente etichetta correttamente il cluster e ottiene una precisione più scarsa rispetto al primo metodo nell'associare le istanze ai cluster corretti.

3.2.1 Cluster Analysis

Con il termine Cluster Analysis, o analisi dei gruppi, si intendono le procedure che permettono di individuare, all'interno di un insieme di oggetti di qualsiasi natura, alcuni sottinsiemi, **clusters** appunto, mutuamente esclusivi e tendenzialmente omogenei al loro interno. Le tecniche di Cluster Analysis creano i gruppi in modo tale che ogni osservazione sia molto simile a tutte le altre che appartengono allo stesso gruppo, in funzione di alcuni criteri prestabiliti. Alla fine del procedimento, i cluster finali dovrebbero esibire un'alta omogeneità interna (intra-cluster) ed un'alta eterogeneità esterna (inter-cluster), quindi gli oggetti all'interno dei cluster saranno vicini tra loro, mentre gli oggetti che appartengono a differenti cluster saranno più lontani tra loro.

La cluster analysis rientra tra le tecniche di tipo esplorativo e pertanto non è




Figura 3.5: Rappresentazione dei dati e dei gruppi ottenuti con la cluster analysis

necessaria alcuna assunzione a priori, anche se impone una serie di decisioni durante l'analisi:

- Scelta delle variabili;
- Criteri di similarità o distanza;
- Tecniche di aggregazione;
- Numero dei gruppi da ottenere;
- Valutazione della qualità della soluzione;
- Scelta fra le diverse possibili soluzioni.

Per classificare e raggruppare gli elementi in gruppi omogenei, è necessario introdurre una nozione di prossimità o similarità. Un indice di prossimità tra due generici elementi x_i e x_j è definito come una funzione dei rispettivi vettori riga nella matrice dei dati: $IP_{ij} = f(x'_i, x'_j)$, $i, j = 1, 2, \dots, n$. Due individui sono vicini quando la loro dissimilarità o distanza è piccola o, equivalentemente, quando la loro similarità è grande. Le principali misure di similarità sono illustrate in tabella 3.1.

I principali algoritmi di clustering sono descritti nelle prossime sottosezioni.

K-Means

Il K-Means è un algoritmo di clustering partizionale che permette di suddividere un insieme di oggetti in K gruppi sulla base dei loro attributi. E' una

Tipo di dato	Misura	Formula
Binario	Coefficiente di Sokal	$S_{ij} = (a + d)/(a + b + c + d)$
Binario	Coefficiente di Jaccard	$S_{ij} = a/(a + b + c)$
Categorici non binari	Media delle variabili	$S_{ij} = (1/p) \sum_{k=1}^p s_{ijk}$
Dati Continui	Distanza Euclidea	$d_{ij} = [\sum_{k=1}^p (x_{ik} - x_{jk})^2]^{1/2}$
Dati Continui	Distanza City Block	$d_{ij} = \sum_{k=1}^p x_{ik} - x_{jk} $

Tabella 3.1: Misure di Similarità

variante dell'algoritmo di aspettativa-massimizzazione(EM) il cui obiettivo è determinare i K gruppi di dati generati da distribuzioni gaussiane. Si assume che gli attributi degli oggetti possano essere rappresentati come vettori e che quindi formino uno spazio vettoriale. L'obiettivo che l'algoritmo di prepone è di minimizzare la varianza intra-cluster, dove ogni cluster viene indentificato mediante un centroide o punto medio. L'algoritmo segue una procedura iterativa:

1. Crea K partizioni (dove K è il numero di cluster che si vogliono ottenere) ed assegna ad ogni partizione dei punti di ingresso (scelti casualmente o euristicamente);
2. Costruisce una nuova partizione associando ogni punto d'ingresso al cluster il cui centroide è più vicino ad esso;
3. Vengono ricalcolati i centroidi per i nuovi cluster e si itera al punto 2 finché l'algoritmo non converge.

L'algoritmo converge molto velocemente, infatti è stato osservato che il numero di iterazioni è minore del numero di punti da osservare. In termini di qualità delle soluzioni, però, l'algoritmo non garantisce il raggiungimento dell'ottimo globale poiché la soluzione dipende largamente dal set di cluster iniziale. Un rimedio a questo aspetto è di applicare l'algoritmo più volte e, fra tutte le soluzioni prodotte, scegliere quella più soddisfacente. Un altro svantaggio è che l'algoritmo richiede di scegliere a priori il numero di cluster da trovare, per cui se i dati non sono naturalmente partizionati si ottengono risultati strani. Inoltre, l'algoritmo funziona bene solo quando sono individuabili cluster sferici nei dati.

K-Medoids

K-medoids è un algoritmo di clustering partizionale correlato all'algoritmo K-means. Prevede in input un insieme di n oggetti e un numero k che determina quanti cluster si vogliono in output. Entrambi gli algoritmi sono partizionali (suddividendo il dataset in gruppi) ed entrambi cercano di minimizzare l'errore quadratico medio, la distanza tra punti di un cluster e il




Figura 3.6: Esempio di assegnazione dei dati tramite l'algoritmo k-means

punto designato per esserne il centro. In K-means il punto è "artificiale" — è la pura media di tutti i punti nel cluster. Nel K-medoids è usato il punto collocato più centralmente, in questo modo il centro è uno dei datapoint attuali. K-medoids è più robusto al rumore e agli outlier rispetto al k-means. Un medoid può essere definito come un oggetto di un cluster la cui dissimilarità media rispetto a tutti gli oggetti nel cluster è minima, in questo modo esso sarà il punto più centrale di un dato dataset. L'algoritmo di clustering è il seguente:

1. Si scelgono arbitrariamente k oggetti (dove K è il numero di cluster che si vogliono ottenere) come punti medoid da un insieme di n data point ($n > k$);
2. In seguito alla selezione di k punti medoid, si associa ogni oggetto nel dato dataset al più simile medoid. La similarità è definita usando misure di distanza;
3. Si seleziona in modo casuale un oggetto non medoid O' ;
4. Si calcola il costo totale S per lo scambio del medoid iniziale nell'oggetto O' ;
5. Se $S < 0$, allora si scambia il medoid iniziale con il nuovo (se $S < 0$ allora ci sarà un nuovo insieme di medoid);
6. Si ripetono i passi dal 2 al 5 sino a quando si hanno cambiamenti nel medoid.




Figura 3.7: Esempio di assegnazione dei dati tramite l'algoritmo k-medoids

Hierarchical

Il clustering gerarchico è un approccio di clustering che mira a costruire una gerarchia di cluster. Le strategie per il clustering gerarchico sono tipicamente di due tipi:

- Agglomerativo: si tratta di un approccio "bottom up" (dal basso verso l'alto) in cui si parte dall'inserimento di ciascun elemento in un cluster differente e si procede quindi all'accorpamento graduale di cluster a due a due;
- Divisivo: si tratta di un approccio "top down" (dall'alto verso il basso) in cui tutti gli elementi si trovano inizialmente in un singolo cluster che viene via via suddiviso ricorsivamente in sotto-cluster.

Il risultato di un clustering gerarchico è rappresentato in un dendrogramma. Questo è uno strumento grafico per la visualizzazione del coefficiente di similarità quantificato dalle varie macchine e dai vari cluster nel processo di "raggruppamento". Il dendrogramma viene utilizzato per fornire una rappresentazione grafica del processo di raggruppamento delle istanze che esprime nell'asse delle ascisse la distanza logica dei clusters secondo la metrica definita, nell'asse delle ordinate il livello gerarchico di aggregazione (valori interi positivi). La scelta del livello gerarchico (del valore dell'asse Y) definisce la partizione rappresentativa del processo di aggregazione.

Per decidere quali cluster devono essere combinati (approccio agglomerativo) o quale cluster deve essere suddiviso (approccio divisivo) è necessario definire una misura di dissimilarità tra cluster. Nella maggior parte dei metodi di

clustering gerarchico si fa uso di metriche specifiche che quantificano la distanza tra coppie di elementi e di un criterio di collegamento che specifica la dissimilarità di due insiemi di elementi (cluster) come funzione della distanza a coppie tra elementi nei due insiemi. Le metriche di distanza più comuni sono: euclidea, Manhattan, uniforme, Mahalanobis, Hamming. Le metriche più diffuse sono: complete linkage (massimo distanza tra due punti), single linkage (massimo distanza tra due punti) o average linkage (massimo distanza tra due punti).




Figura 3.8: Esempio di assegnazione dei dati tramite cluster gerarchico e la sua rappresentazione tramite dendrogramma

Neural Networks

Le self-organizing map (SOM) sono una fattispecie di organizzazione di processi di informazione in rete analoghi alle reti neurali artificiali. È addestrata usando l'apprendimento non supervisionato per produrre una rappresentazione dei campioni di training in uno spazio a bassa dimensione preservando le proprietà topologiche dello spazio degli ingressi. Questa proprietà rende le SOM particolarmente utili per la visualizzazione di dati di dimensione elevata. Le self-organizing map sono reti neurali a connessioni laterali dove i neuroni di uscita sono organizzati in griglie di bassa dimensione (generalmente 2D o 3D). Ogni ingresso è connesso a tutti i neuroni di uscita. A ogni neurone è associato un vettore dei pesi della stessa dimensione dei vettori

d'ingresso. La dimensione del vettore d'ingresso è generalmente molto più alta della dimensione della griglia di uscita. L'obiettivo dell'apprendimento nelle self-organizing map è di specializzare parti differenti del reticolo SOM a rispondere similmente a particolari pattern d'ingresso.

L'algoritmo di clustering è il seguente:

1. Assegna ai vettori dei pesi valori casuali;
2. Prendi un vettore d'ingresso;
3. Attraversa ogni nodo della mappa ed usa la distanza euclidea per trovare somiglianze fra il vettore d'ingresso ed il vettore dei pesi di ogni singolo nodo della mappa, individuando il nodo a distanza minore (questo nodo verrà chiamato Best Matching Unit o BMU);
4. Aggiorna i nodi del vicinato di BMU "tirandoli" più vicino al vettore d'ingresso.

Ci sono due modi per interpretare una SOM:

- Dato che nella fase di addestramento i pesi di tutto il vicinato sono spostati nella stessa direzione, elementi simili tendono ad eccitare neuroni adiacenti. Perciò le SOM formano una mappa semantica dove campioni simili vengono mappati vicini e dissimili distanti;
- Un altro modo di considerare i pesi neuronali è di pensarli come punti distribuiti nello spazio degli ingressi. Questi formano un'approssimazione della distribuzione dei campioni d'ingresso. Più neuroni puntano a regioni con un'elevata concentrazione di campioni di addestramento, e meno in zone dove i campioni sono scarsi.




Figura 3.9: Schema input-output per una SOM

Fuzzy C-Means

Il Fuzzy C-means (anche riferito come soft clustering) è un algoritmo di clustering nel quale ogni punto può appartenere a più di un cluster. L'algoritmo è molto simile al k-means, ma in questo contesto viene assegnato ad ogni punto un grado di appartenenza. Questo indica il grado con cui un determinato punto appartiene ad un certo cluster. L'algoritmo di clustering è il seguente:

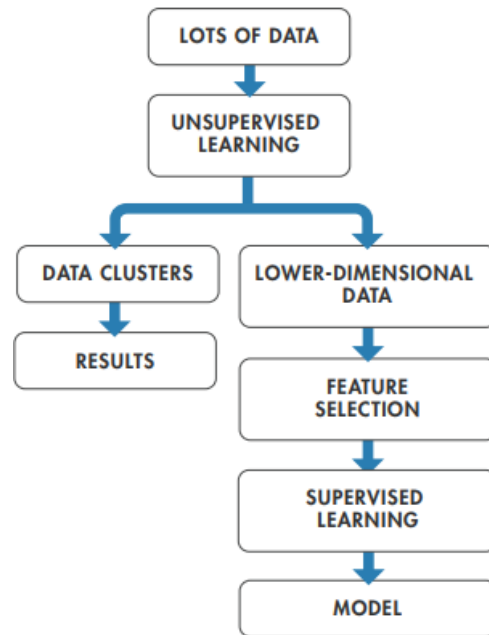


Figura 3.10: Rappresentazione dei possibili approcci usando strategie di clustering

1. Scegliere un numero K di cluster;
2. Assegna randomicamente dei coefficienti di appartenenza ad un cluster per ogni punto;
3. Calcola il centroide di ogni cluster;
4. Per ogni punto, calcola il suo grado di appartenenza ai clusters;
5. Itera fino ad avere convergenza.

3.2.2 Classificazione

I principali approcci di classificazione sono due. In un modello parametrico, il modello stesso è preventivamente caratterizzato da un vettore X di parametri: si suppone quindi che esista una relazione tra features e input e che tale relazione sia rappresentabile all'interno di una famiglia di relazioni parametriche rispetto a X che costituisce un modello; in altre parole, un'assegnazione di valori al vettore X definisce una specifica relazione della famiglia. Gli elementi nel training set sono utilizzati proprio per derivare tale assegnazione di valori ai parametri (o una distribuzione di probabilità

per tali valori), dopo di che non sono più utilizzati. In un modello non parametrico, invece, il numero di parametri cresce con la dimensione del training set: sostanzialmente, ogni singola previsione, in questo caso, richiede l'utilizzo dell'intero training set. Un esempio di approccio non parametrico sono i classificatori di tipo nearest neighbor, in cui si determina l'elemento x_i del training set più vicino a x e si impone il valore della nuova previsione y associata a x uguale al valore y_i dell'elemento x_i .

I principali algoritmi di classificazione sono:

- **Decisione Tree:** si tratta di un classificatore con struttura ad albero, in cui ogni nodo può essere o foglia o nodo interno: se foglia, indica il valore della classe assegnata all'istanza; se nodo interno, specifica il test effettuato su un attributo. Per ciascun valore assunto da un attributo in un test, l'algoritmo crea un ramo ed il relativo sottoalbero. Il focus principale dell'algoritmo di crescita del decision tree è come scegliere gli attributi da testare in ciascun nodo interno dell'albero. L'obiettivo è selezionare gli attributi più utili per classificare le istanze di training attraverso una strategia top down, che consiste in una ricerca greedy degli attributi senza tornare a riconsiderare le precedenti scelte. Il criterio di split (suddivisione) con cui crea un nuovo nodo si basa sul massimo guadagno di informazione (info gain). In pratica sceglie l'attributo che riesce a dividere "meglio" le istanze appartenenti a classi diverse (detto anche criterio di massima riduzione di incertezza). Quando tutti gli elementi in un nodo hanno la medesima classe, l'algoritmo non procede con ulteriore split (criterio di stopping).
- **K-Nearest-Neighbors:** esso memorizza le istanze del training, poi, basandosi su un criterio di vicinanza, mette in relazione l'istanza da classificare con alcune istanze del training set presenti nello spazio delle feature. In pratica, l'istanza è classificata "a maggioranza" in base alla classe più comune tra le k istanze più vicine del training. Tutto il lavoro è fatto dal classificatore in runtime. Data una nuova istanza x da classificare, il classificatore cerca i k esempi del training che sono più "simili" a x e guarda le loro etichette. Qualsiasi label ricorra più frequentemente tra le k label più vicine è scelta per assegnare la classe a x .
- **Support Vector Machine:** l'idea principale di questo classificatore consiste nel rappresentare gli esempi del training come punti nello spazio mappati in modo tale che punti appartenenti a classi differenti siano separati dal più ampio gap possibile. I punti che mappano il test set saranno assegnati ad una categoria o all'altra in base al lato del gap su cui cadono. Più specificatamente, SVM costruisce un iperpiano ed esegue una buona separazione quando l'iperpiano ha la più ampia distanza dai punti di training più vicini di ciascuna classe. Ci sono molti

iperpiani che potrebbero classificare il dato. La miglior scelta è quella di selezionare l'iperpiano che rappresenta la più ampia separazione, o margine, tra due classi, ossia l'iperpiano tale che la distanza tra esso e il punto più vicino su ciascun lato sia massima.

3.2.3 Validazione della Classificazione

Al fine di valutare la bontà della classificazione effettuata, viene introdotto il concetto di **Matrice di Confusione**. Essa è una matrice $n \times n$, con n =numero di classi, nella quale vengono messe a confronto le etichette reali con quelle del classificatore proposto. La figura 3.11 rappresenta la matrice di confusione con 2 classi possibili:

- Il **Vero Positivo** indica quante volte ho classificato giusto l'etichetta che io considero come positiva, ad esempio la classe 1;
- Il **Vero Negativo** indica quante volte ho classificato giusto l'etichetta che io considero come negativa, ad esempio la classe 2;
- Il **Falso Positivo** indica quante volte ho classificato sbagliato l'etichetta che io considero come positiva, ossia il mio classificatore ha etichettato il mio campione con la classe 1, ma in realtà quella misurazione appartiene alla classe 2;
- Il **Falso Negativo** indica quante volte ho classificato sbagliato l'etichetta che io considero come negativa, ossia il mio classificatore ha etichettato il mio campione con la classe 2, ma in realtà quella misurazione appartiene alla classe 1;

		Indici predetti	
Indici reali		Classificazione positiva	Classificazione negativa
	Presenza di condizione	Vero positivo <i>tp</i>	Falso negativo <i>fn</i> (<i>type II error</i>)
	Assenza di condizione	Falso positivo <i>fp</i> (<i>type I error</i>)	Vero negativo <i>tn</i>

Figura 3.11: Rappresentazione della matrice di confusione per 2 classi

La condizione ideale di classificazione sarebbe quella in cui la matrice di confusione è diagonale, ossia non presento falsi positivi o falsi negativi. Da questa si possono ricavare varie misure, tutte nell'intervallo $[0,1]$:

- **Accuratezza:** $\frac{tp + tn}{tp + tn + fp + fn}$
- **Precisione:** $\frac{tp}{tp + fp}$
- **Sensitività:** $\frac{tp}{tp + tn}$
- **F1-measure:** $\frac{2 * precisione * sensitività}{sensitività + precisione}$
- **Specificità:** $\frac{tn}{fp + tn}$

Nel caso di più classi, di possono generalizzare le misure di precisione e sensitività associate alle singole classe, mentre il concetto di accuratezza resta sempre lo stesso. La figura 3.12 rappresenta la generalizzazione delle formula suddette.

$$precisione_c = \frac{tp}{tp + fp} = \frac{Conf(c, c)}{\sum_d Conf(d, c)}$$

$$sensitività_c = \frac{tp}{tp + fn} = \frac{Conf(c, c)}{\sum_d Conf(c, d)}$$

Figura 3.12: Rappresentazione della matrice di confusione per c classi

3.3 Riduzione della dimensionalità

3.3.1 Analisi Delle Componenti Principali

L'analisi in componenti principali o **PCA** è una tecnica per la semplificazione dei dati, con lo scopo primario di ridurre un numero più o meno elevato di variabili in alcune caratteristiche latenti. Questo procedimento prende il nome di **feature reduction**. Ciò avviene tramite una trasformazione lineare delle variabili che proietta quelle originarie in un nuovo sistema cartesiano nel quale la nuova variabile con la maggiore varianza viene proiettata sul primo asse, la seconda variabile per dimensione della varianza sul secondo




Figura 3.13: Rappresentazione del cambio di dimensionalità tramite PCA

asse e così via. La riduzione della complessità avviene quindi limitandosi ad analizzare le principali (per varianza) tra le nuove variabili. Diversamente da altre trasformazioni lineari, in questa tecnica sono gli stessi dati che determinano i vettori di trasformazione.

Un metodo per calcolare la componente w_i (ossia quella che effettua la trasformazione per la variabile i) utilizza la **matrice delle covarianze** di x , mentre un altro metodo possibile usa la matrice dei coefficienti di correlazione. Innanzitutto, si devono trovare gli autovalori della matrice di covarianza: Si ottengono così tanti autovalori quante sono le variabili x . L'autovalore con il maggiore valore corrisponde alla dimensione w che ha la maggior varianza: esso sarà dunque la varianza della componente principale numero 1. Per ciascun autovalore viene calcolato il corrispondente autovettore, ossia la matrice dei coefficienti che moltiplicano le vecchie variabili x nella combinazione lineare per l'ottenimento delle nuove variabili w . La matrice degli autovettori degli autovettori viene definita anche matrice di rotazione V e, eseguendo l'operazione $W = V * X$, dove W è il vettore colonna avente come elementi le nuove variabili w_1, w_2, \dots e X è il vettore colonna avente come elementi le vecchie variabili x_1, x_2, \dots , si possono trovare le coordinate di ciascun punto nel nuovo spazio vettoriale. Alla fine, quindi, si tengono solo le componenti le quali, sommate tra di loro, esprimono una certa varianza (es. 90% della varianza dei dati), mentre le altre vengono ignorate. In questo modo, par-

tendo da n variabili iniziali, posso arrivare a $(n-k)$ nuove variabili, dove k è il numero di componenti che non mi servono per raggiungere la soglia di varianza prefissata.

3.3.2 Analisi dei Discriminanti Lineari

Mentre la PCA è utile per la rappresentazione dei pattern (es. riconoscimento di immagini), l'analisi dei discriminanti lineari o **LDA** viene usata per discriminare tali pattern, ossia per trovare delle misure che mi permettano di dividere in più classi i miei dati. Entrambe vengono usate per la riduzione della dimensionalità delle variabili di input).

L'obiettivo della LDA è quello di trovare un vettore w , di trasformazione, tale per cui classi differenti siano ben separate, mentre la diffusione di ogni classe sia ridotta il più possibile. In pratica, si tratta di trovare una soluzione al cosiddetto criterio di Fisher:

$$J_F = \frac{w^T S_B w}{w^T S_w w} \quad (3.1)$$

, nella quale S_B ed S_W sono rispettivamente la matrice di dispersione tra le classi e la matrice di dispersione all'interno della classe. Nel caso di due classi, la S_B si calcola come:

$$S_B = (m_1 - m_2)(m_1 - m_2)^T \quad (3.2)$$

, dove m_1 rappresenta la media della classe 1 e m_2 quella della classe 2. S_w , invece, si calcola come

$$S_W = \sum_{i=1}^c \sum_{x \in w_i} (x - m_i)(x - m_i)^T \quad (3.3)$$

con m_i = media della classe i e c = numero di classi.

La soluzione del criterio di Fisher viene chiamata anche **Problema dell'Autovalore Generalizzato** e viene rappresentata da tale equazione:

$$S_B w = \lambda S_w w \quad (3.4)$$

e, se S_w è invertibile, diventa

$$S_w^{-1} S_B w = \lambda w \quad (3.5)$$

, corrispondente al problema degli autovalori regolari che coinvolge $S_w^{-1} S_B$. Una volta che w viene trovato, le feature cercate vengono calcolate:

$$y = w^T x \quad (3.6)$$

le quali possono essere usate per allenare l'algoritmo di classificazione scelto e procedere alla predizione su nuovi dati.




Figura 3.14: Rappresentazione del cambio di dimensionalità tramite LDA

Nel caso si abbiano più di 2 classi, la matrice di dispersione tra le classi, la quali misura la separazione tra le classi, diventa:

$$S_B = \sum_{i=1}^c n_i (m_i - m)(m_i - m)^T \quad (3.7)$$

con n_i = numero di campioni di training appartenenti alla classe i ed m = media di tutti i campioni di training. Ci saranno quindi $C-1$ autovettori, ognuno proveniente da una soluzione di (3.5), che potrebbero non essere ortogonali tra loro ma formano uno sottospazio lineare tale per cui il criterio di Fisher è massimizzato. Questi vengono inseriti in una matrice W e si calcolano le feature come in (3.6).

Motivazioni ed obiettivi

Quello del FoG, come introdotto in precedenza, è un problema che debilita in modo anche grave il paziente affetto da Parkinson. L'obiettivo della nostra metodologia è quello di prevenire le situazioni di FoG, attraverso l'identificazione di pattern o condizioni che portano il paziente a bloccarsi ed incorrere nel rischio di cadere. A tale scopo, è necessario sviluppare una metodologia che permetta di identificare tali avvenimenti, quindi fornisca, nel modo più accurato possibile, l'informazione sulla presenza o meno di FoG, per poi definire anche gli istanti immediatamente precedenti al blocco, che chiamiamo pre-FoG. Una volta che si riconoscono tali intervalli, tramite uno stimolo auditorio dato nella fase di pre-FoG si può evitare l'occorrenza del FoG e quindi permette al paziente di continuare nell'attività che stava svolgendo senza che abbia blocchi o rischi di cadere.

Quello che, dunque, si vuole progettare è un algoritmo automatizzato non supervisionato che, attraverso l'uso di accelerometri posizionati sul paziente, permetta di identificare, in tempo reale, gli istanti che chiamiamo pre-FoG e quindi prevenire il blocco della persona. Questo permette di sostituire il dottore, o fisioterapista, nell'identificazione di episodi di FoG anche nella prima fase di test.

Infatti, fino ad adesso, al paziente venivano fatti fare dei percorsi ed il dottore, tramite l'utilizzo di registrazioni, registrava i FoG ed etichettava dunque tutti gli istanti della registrazione in base all'occorrenza del blocco oppure no. Con questo approccio, invece, tutto questo viene effettuato dall'algoritmo, senza il bisogno dell'intervento umano.

Dopo una prima fase di test, a questo punto automatizzata, l'algoritmo cerca di adattarsi il più possibile alle abitudini di camminata e di reazione del paziente, al fine di sbagliare il meno possibile. In un contesto di vita quotidiana, poi, l'algoritmo viene eseguito sullo stesso dispositivo che contiene l'accelerometro, per cui anche l'invasività degli strumenti utilizzati è minima. L'indossabile allora raccoglie i dati degli accelerometri ed, ad ogni finestra temporale, esegue l'algoritmo sviluppato che definisce il tipo di situazione in cui il paziente si trova, se a rischio di FoG o non in blocco. Nel primo caso, il dispositivo stesso effettua lo stimolo auditivo al fine di evitare l'occorrenza

di FoG, mentre nel secondo caso resta silente.

Riassumendo, l'obiettivo è quello di sviluppare un algoritmo automatizzato che permetta di prevenire i contesti di FoG, senza la supervisione del fisioterapista o del dottore, tramite l'utilizzo di uno o più dispositivi indossabili che facciano uso di accelerometri.

Apprendimento non supervisionato per l'identificazione di contesti di FoG

I lavori che sono stati svolti e presentati nel capitolo 2 sul Freezing Of Gait sono basati su approcci di classificazione ossia, come spiegato nel capitolo 3, allenano un algoritmo con dei dataset di training nel quale le etichette di ogni istante vengono fornite dalla supervisione di un dottore o fisioterapista e poi, tale algoritmo allenato, viene testato su dei nuovi dati al fine di rilevare i contesti di FoG. Il lavoro che viene presentato in questo capitolo, invece, usa le etichette fornite dal dataset solo come confronto ai risultati forniti dagli algoritmi di clustering. Quest'ultimi, infatti, una volta forniti i dati o feature (proprietà) su cui voglia applicarli, restituiscono, per ogni osservazione (nel nostro caso riga del dataset), un'etichetta che indica a quale contesto è stato assegnato ogni dato, se di FoG, non-FoG o Pre-FoG.

Innanzitutto verrà fornita una descrizione del dataset utilizzato e di come è stato modificato per le nostre esigenze. Verranno poi descritti i metodi utilizzati dall'approccio scelto e viene fornito il codice implementativo. Tutto lo sviluppo è stato effettuato tramite software Matlab ¹.

5.1 Dataset

L'approccio che andiamo a proporre è stato testato sul dataset DAPHNET², il quale contiene dati collezionati da 10 pazienti parkinsoniani, dei quali 8 presentano contesti di FoG, mentre 2 di loro non ne presentano. I dati sono stati registrati usando 3 accelerometri 3D attaccati alla caviglia, al ginocchio e nella zona lombare del paziente, usando una frequenza di campionamento di 64 Hz, ossia vengono raccolti 64 campioni ogni secondo.

I soggetti hanno completato sessioni da 20-30 minuti ciascuno, consistenti di 3 fasi di camminata:

1. Camminata avanti ed indietro lungo una linea retta, con delle rotazioni di 180 gradi;

¹<https://it.mathworks.com/products/matlab.html>

²www.wearable.ethz.ch/resources/Dataset

2. Camminata casuale con una serie di fermate volontarie e rotazioni di 360 gradi;
3. Camminata che simula attività di vita quotidiana, tra le quali entrare in stanze ed uscirne, camminare nella cucina, prendersi un bicchiere d'acqua e tornare al punto di partenza.

Le prestazioni motorie variano molto tra i pazienti. Mentre alcuni soggetti hanno mantenuto una camminata regolare durante gli episodi di non FoG, altri hanno camminato molto lentamente ed in modo instabile. L'intero dataset contiene in totale 237 episodi di FoG; la durata di ognuno di essi è tra i 0.5s ed i 40.5s. Il 50% degli episodi di FoG è durato meno di 5.4s ed il 93.2% è più corto di 20s. Gli episodi di FoG sono stati identificati da fisioterapisti usando registrazioni video sincronizzate. L'inizio di un episodio di FoG è stato definito come il punto dove la sequenza normale di camminata è stata interrotta, mentre la fine del FoG è stata definita come il momento in cui tale sequenza riprende.

Per il lavoro svolto nella tesi, oltre alle etichette date dai dottori nei casi di non FoG e FoG, abbiamo introdotto nei dati una nuova label, che indica il momento che noi indichiamo come pre-FoG, per cui tutti i campioni precedenti ad un'occorrenza di FoG sono stati etichettati con questa nuova label. Quindi ci ritroviamo con 3 label diverse invece di 2 (tutti i lavori in letteratura rientrano nell'ultimo caso): l'etichetta 1 indica un No-FoG, la label 2 indica un FoG, l'etichetta 3 indica invece un pre-FoG.

5.2 Approccio basato su Feature Statistiche

I dati raccolti dagli accelerometri, se presi in forma grezza, hanno poca potenza espressiva, ossia non riescono a fornire molte informazioni su ciò che stiamo cercando (contesti di FoG), quindi si rende necessaria una rimodellazione di tali dati. Il primo approccio che è stato preso in considerazione è basato sul calcolo di feature (o proprietà) basate su grandezze che provengono dalla matematica statistica. Il flusso di tale approccio è:

1. Pre-processamento dei dati degli accelerometri, al fine di eliminare il rumore presente ed identificare eventuali punti di outline, ossia campioni che non presentano affinità col resto dei dati poiché dovuti a movimenti non consoni;
2. Finestramento dei dati in base ad intervalli variabili al fine di calcolare le feature, dove ogni intervallo presenta una certa sovrapposizione con l'intervallo precedente;
3. Calcolo effettivo delle feature statistiche;
4. Applicazione degli algoritmi di clustering;

5. Calcolo di metriche che indicano quanto bene gli algoritmi di clustering hanno lavorato in relazione alle label fornite dal dataset.

5.2.1 Pre-processamento dei dati

Gli accelerometri sono dispositivi che misurano le vibrazioni o l'accelerazione del movimento di una struttura. La forza generata dalle vibrazioni o una variazione del movimento (accelerazione) fa in modo che la massa "comprima" il materiale piezoelettrico, che genera una carica elettrica proporzionale alla forza esercitata su di esso. Dato che la carica è proporzionale alla forza e che la massa è una costante, la carica è proporzionale anche all'accelerazione. Come tutti i dispositivi che misurano delle grandezze presentano dell'incertezza strumentale che può portare ad avere rumore, ossia un segnale non desiderato, di origine naturale o artificiale, che si sovrappone all'informazione degli accelerometri stessi. Questo rumore porta ad avere dei punti definiti outlier, ossia campioni che non presentano affinità col resto dei dati poiché dovuti a movimenti non consoni.

Al fine di rimuovere tali punti, che altererebbero in modo negativo il calcolo delle nostre feature, si rende necessario rimuoverli dal nostro dataset. Per identificarli, è stato implementato un filtro passa-alto che eliminano tutte le frequenze inferiori a 0.5Hz, le quali non appartengono al normale movimento umano ma indicano appunto la presenza di rumore, come evidenziato in [21]. L'implementazione del filtro viene fornita in 5.1.

Listing 5.1: hpfilter

```
% All frequency values are in Hz.
Fs = 64; % Sampling Frequency

Fstop = 0.4; % Stopband Frequency
Fpass = 0.8; % Passband Frequency
Astop = 60; % Stopband Attenuation (dB)
Apass = 1; % Passband Ripple (dB)
match = 'passband'; % Band to match exactly

% Construct an FDESIGN object and call its ELLIP method.
h = fdesign.highpass(Fstop, Fpass, Astop, Apass, Fs);
Hd = design(h, 'cheby2', 'MatchExactly', match);
```

5.2.2 Definizione degli intervalli

5.2.3 Calcolo delle Feature

Le feature prese in considerazione nel nostro studio sono descritte in tabella 5.1.

N	Feature	Descrizione
1	Minimo	Valore minimo del segnale
2	Massimo	Valore massimo del segnale
3	Mediana	Valore mediano del segnale
4	Media	Valore medio del segnale
5	Media Armonica	Media armonica del segnale
6	Errore Quadratico Medio	Valore Quadratico medio del segnale
7	Media Geometrica	Media geometrica del segnale
8	Varianza	Radice della deviazione standard
9	Deviazione Standard	Deviazione media del segnale rispetto alla media
10	Curtosi	Allontanamento dalla normalità distributiva del segnale
11	Simmetria	Grado di asimmetria della distribuzione del segnale
12	Moda	Il numero che appare più volte nel segnale
13	Media Tagliata	Media tagliata del segnale nella finestra
14	Entropia	Misura della di distruzione delle componenti in frequenza
15	Range	Differenza tra il valore minimo e massimo del segnale
16	Magnitudine	Somma della norma euclidea di tre assi normalizzato sulla lunghezza del segnale
17	Area Magnitudine	Accelerazione della magnitudine di tre assi normalizzato sulla lunghezza del segnale
18	Autovalori delle direzioni dominanti	Autovalori della matrice di covarianza di tre assi
19	Accelerazione media dell'energia	Valore medio dell'energia sui 3 assi

Tabella 5.1: Descrizione delle Feature Statistiche

Prima di calcolare tali feature, però, è necessario pre-processare i dati in modo da eliminare il più possibile il rumore presente o gli outlier. A tale scopo, è stato progettato un filtro passa banda in modo da eliminare tutti i movimenti che presentano una frequenza inferiore a 0.5Hz o superiore a 20Hz, in accordo con [21], dato che il movimento umano è compreso tra questi due valori.

Una volta filtrati i dati, il passo successivo è scegliere l'intervallo della finestra temporale su cui calcolare le feature. Questa però non ha una lunghezza definita a priori in letteratura, per cui abbiamo condotto uno studio su quale fosse la migliore scelta. Inoltre, poiché non vogliamo perdere determinati

movimenti tra una finestra e l'altro, per cui si è deciso di fare sovrapposizione tra finestre. Anche questo parametro non è definito a priori, per cui anche questo valore è stato fatto variare e condotto un studio su quale fosse il migliore. I range su cui sono stati fatti i test sono: da 1 a 5 secondi per quanto riguarda la dimensione della finestra temporale, da 0.5 a 4.5 secondi invece per l'intervallo di sovrapposizione, con la condizione che il tempo di sovrapposizione sia sempre minore di quello della finestra. Per esempio, poiché ho una frequenza di campionamento di 64 Hz, scegliendo 2 secondi come intervallo della finestra e 0.5 secondi di overlap, avrò che la prima finestra va dal campione 1 al campione 129, la seconda finestra va dal campione 98 al campione 226, la terza finestra dal campione 195 al campione 323 e così via. L'intervallo che invece è stato definito a priori è quello relativo al pre-fog, che è stato posto a 2s in accordo con [23]. Per ogni combinazione di fine-

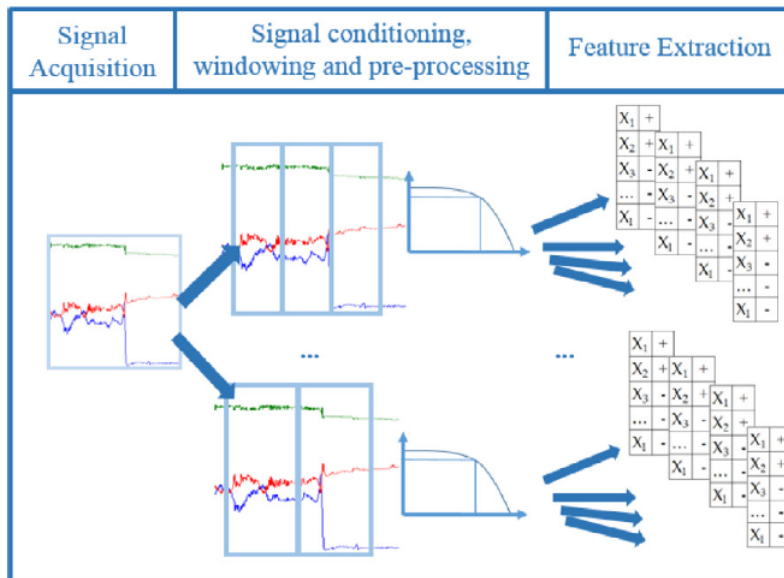


Figura 5.1: Schema generale di calcolo delle feature statistiche

stra temporale, quindi, vengono calcolate le rispettive feature e si procede ad applicare l'algoritmo di clustering. Quelli che sono stati scelti, in quanto più diffusi nel contesto di clustering, sono: k-means, self-organizing map e fuzzy c-means. Il k-means viene testato con tutte le sue metriche di distanza, per evidenziare eventuali differenze e decidere quale tra le 4 presenti (cosine, euclidean, cityblock, correlation) si adatta di più al nostro problema. Il fuzzy c-means è stato scelto anche perché è di soft clustering, ossia 2 punti potrebbero appartenere a 2 cluster diversi, il che ritorna utile nel trovare correttamente la terza label, in quanto nel dataset originale era etichettata con una diversa label.

Ogni algoritmo di clustering restituisce un vettore di etichette, che indica-




Figura 5.2: Grafico degli intervalli di overlap e secondi della finestra temporale per ogni paziente

no il numero di cluster a cui è stato assegnato ogni punto. Questi vengono messi a confronto con le true label, ossia le etichette inserite a mano dal dottore, e si calcolano le metriche di accuratezza, precisione, sensibilità e F1-measure attraverso la matrice di confusione descritta precedentemente. Le true label vengono calcolate, per ogni vettore di feature, come la moda tra le label della finestra temporale, ossia come l'etichetta che si presenta più volte all'interno della finestra stessa. Una volta ottenute le misure per tutti i campioni temporali, si cercano gli intervalli con il maggiore punteggio, dove con quest'ultimo intendiamo la media delle 4 grandezze calcolate. Nel nostro caso, come si vede nella figura 5.2, abbiamo che i punteggi migliori vengono raggiunti nell'intervallo compreso tra 1.5 e 2 secondi, con una sovrapposizione di 0.5 o 1 secondo. Dato che nella maggior parte dei casi risultano tali intervalli, decidiamo di concentrarci su questi, anche perché sono accettabili in un'implementazione online. Nella figura 5.3 si può vedere il valore di accuratezza per ogni paziente per i vari algoritmi di clustering, mentre nella figura 5.4 possiamo osservare la precisione per ogni paziente ed infine nella figura 5.5 si può vedere il valore di recall per ogni algoritmo e paziente.

Oltre a determinare le migliori combinazioni secondi-overlap, siamo stati in grado di verificare quale metrica dell'algoritmo di clustering k-means meglio si adatta ai nostri dati. Infatti, nella figura 5.3 possiamo vedere che la metrica Euclidean ha in media il valore più alto rispetto alle altre, anche se questo, osservando le figure 5.4 e 5.5, è dato dal fatto che sbaglia meno volte rispetto alle altre metriche ad etichettare il NoFog e, essendo questa label in quantità maggiore rispetto alle altre, porta ad un'accuracy totale più alta.




Figura 5.3: Grafico dell'accuratezza per ogni paziente




Figura 5.4: Grafico della precisione media delle classi per ogni paziente




Figura 5.5: Grafico della recall media delle classi per ogni paziente

5.3 Feature Dinamiche

5.4 Linear Discriminant Analysis

Conclusione e Lavori Futuri

This thesis proposes a methodology

6.1 Risultati

6.2 Lavori Futuri

Bibliography

Riferimenti bibliografici

- [1] Delval A, Snijders AH, Weerdesteyn V, Duysens JE, Defebvre L, Giladi N e et al. “Objective detection of subtle freezing of gait episodes in Parkinson’s disease.” In: *Mov Disord.* (2010), 25: 1684–1693.
- [2] Nieuwboer A, De Weerd W, Desloovere K, Fieuws S e Broens kaucsik E. “Abnormalities of the Spatiotemporal Characteristics of Gait at the Onset of Freezing in Parkinson ‘ s Disease.” In: *Mov Disord.* (2001), 16: 1066–1075.
- [3] Tay A, Yen SC, Lee PY, Wang CY, Neo A, Phan SW e et al. “Freezing of Gait (FoG) detection for Parkinson Disease.” In: *10th Asian Control Conference (ASCC)* (2015), pp. 1–6.
- [4] Weiss A, Herman T, Giladi N e Hausdorff JM. “Objective assessment of fall risk in Parkinson’s disease using a body-fixed sensor worn for 3 days.” In: *PLoS One* (2014).
- [5] Takač B, Català A, Rodriguez Martin D, van der Aa N, Chen W e Rauterberg M. “Position and Orientation Tracking in a Ubiquitous Monitoring System for Parkinson Disease Patients With Freezing of Gait Symptom.” In: *JMIR mhealth uhealth* (2013), 1: e14.
- [6] Cole BT, Roy SH e Nawab SH. “Detecting Freezing-of-Gait During Unscripted and UNconstrained Activity”. In: *33rd Annual International Conference of the IEEE EMBS* (2011), pp. 5649–5652.
- [7] Ahlrichs C, Samà A, Lawo M, Cabestany J, Rodriguez-Martin D, Pérez-López C e et al. “Detecting freezing of gait with a tri-axial accelerometer in Parkinson’s disease patients.” In: *Med Biol Eng Comput.* (2016), 54: 223–233.
- [8] Coste C, Sijobert B, Pissard-Gibollet R, Pasquier M, Espiau B e Geny C. “Detection of Freezing of Gait in Parkinson Disease: Preliminary Results.” In: *Sensors* (2014), 14: 6819–6827.

- [9] Pérez-López C, Samà A, Rodríguez-Martin D, Català A, Cabestany J e et al. de Mingo E. “Monitoring Motor Fluctuations in Parkinson’s Disease Using a Waist-Worn Inertial Sensor.” In: *International Work Conference on Artificial Neural Networks Advances in Computational Intelligence Lecture Notes on Computer Science*. (2015), pp. 461–474.
- [10] Rodríguez-Martin D, Samà A, Pérez-López C, Català A, Cabestany J e Rodríguez-Molinero A. “A. Posture Detection with waist-worn Accelerometer : An application to improve Freezing of Gait detection in Parkinson ‘ s disease patients.” In: *European Conference on Ambient Assisted Living*. (2014), pp. 1–6.
- [11] Rodríguez-Martin D, Samà A, Pérez López C, Català A, Moreno ArosteGUI JM, Cabestany J e et al. “Home detection of freezing of gait using support vector machines through a single waist-worn triaxial accelerometer”. In: *PLoS ONE* (2017).
- [12] Schaafsma J. D., Gurevich T. Balash Y and, Bartels A. L., Hausdorff J. M. e Giladi N. “Characterization of freezing of gait subtypes and the response of each to levodopa in Parkinson’s disease”. In: *European Journal of Neurology* (2003), 18: 25–29.
- [13] Jovanov E, Wang E, Verhagen L, Fredrickson M e Fratangelo R. “de-FOG: A real time system for detection and unfreezing of gait of Parkinson’s patients.” In: *31st Annual International Conference of the IEEE EMBS*. (2009), pp. 5151–5154.
- [14] Tripoliti EE, Tzallas AT, Tsipouras MG, Rigas G, Bougia P, Leontiou M e et al. “Automatic detection of freezing of gait events in patients with Parkinson’s disease.” In: *Comput Methods Programs Biomed. Elsevier Ireland Ltd* (2013), 110: 12–26.
- [15] Zabaleta H, Keller T e Fimbel EJ. “Gait analysis in frequency domain for freezing detection in patients with Parkinson’s disease.” In: *Gerontechnology*. (2008).
- [16] Zach H, Janssen AM, Snijders AH, Delval A, Ferraye MU, Auff E e et al. “Identifying freezing of gait in Parkinson’s disease during freezing provoking tasks using waist-mounted accelerometry.” In: *Parkinsonism Relat Disord. Elsevier Ltd* (2015), 21: 1362–1366.
- [17] Jiawei Han, Jian Pei e Micheline Kamber. *Data mining: concepts and techniques*. Elsevier, 2011.
- [18] Han JH, Lee WJ, Tae Beom A, Beom Suk J e Kwang Suk P. “Gait analysis for freezing detection in patients with movement disorder using three dimensional acceleration system.” In: *25th Annual International Conference of the IEEE EMBS*. (2003), pp. 1863–1865.

- [19] Hausdorff JM, Balash Y e Giladi N. “Time series analysis of leg movements during freezing of gait in Parkinson’s disease:akinesia,rhyme or reason?” In: *Physica A*. (2003), 321:656–570.
- [20] Niazmand K, Tonn K, Zhao Y, Fietzek UM, Schroeteler F, Ziegler K e et al. “Freezing of Gait detection in Parkinson’s disease using accelerometer based smart clothes.” In: *IEEE Biomedical Circuits and Systems Conference (BioCAS)*. (2011), pp. 201–204.
- [21] Bachlin M, Roggen D, Plotnik M, Hausdorff JM, Giladi N e Troster G. “Online Detection of Freezing of Gait in Parkinson’s Disease Patients: A Performance Characterization.” In: *Proc 4th Int ICST Conf Body Area,Networks*. (2009).
- [22] Handojoseno a MA, Shine JM, Nguyen TN, Tran Y, Lewis SJG e Nguyen HT. “The detection of Freezing of Gait in Parkinson’s disease patients using EEG signals based on Wavelet decomposition”. In: *34th AnnuInt Conf IEEE Eng Med Biol Soc*. (2012), 2012:69–72.
- [23] Sinziana Mazilu, Alberto Calatroni, Eran Gazit, Daniel Roggen, Jeffrey M. Hausdorff e Gerhard Troster. “Feature Learning for Detection and Prediction of Freezing of Gait in Parkinson’s Disease”. In: *Machine Learning and Data Mining in Pattern Recognition* (2013).
- [24] Almeida Q.J. e Lebold C. A. “Freezing of Gait in Parkinson’s Disease: A Perceptual Cause for a Motor Impairment?” In: *Neurol Neurosurg Psychiatry* (2010), 81: 513–518.
- [25] REMPARK. “Personal Health Device for the Remote and Autonomous Management of Parkinson’s Disease.” In: *FP7-ICT-2011-7-287677*. (2011-2014).
- [26] Mazilu S, Calatroni A, Gazit E, Mirelman A, Hausdorff J e Troester G. “Prediction of Freezing of Gait in Parkinson’s from Physiological Wearables: An Exploratory Study.” In: *IEEE J Biomed Heal Informatics*. (2015), 6:1–1.
- [27] Mazilu S, Hardegger M, Zhu Z, Roggen D, Troster G, Plotnik M e et al. “Online Detection of Freezing of Gait with Smartphones and Machine Learning Techniques.” In: *Proc 6th Int ICST Conf Pervasive Comput Technol Healthc*. (2012), pp. 123–130.
- [28] Moore ST, Yungher Da, Morris TR, Dilda V, MacDougall HGa, Shine JM e et al. “Autonomous identification of freezing of gait in Parkinson’s disease from lower-body segmental accelerometry”. In: *Neuroeng Rehabil. Journal of NeuroEngineering and Rehabilitation* (2013).
- [29] Moore ST, MacDougall HG e Ondo WG. “Ambulatory monitoring of freezing of gait in Parkinson’s disease”. In: *J Neurosci Methods* (2008), 167: 340–348.

- [30] Zhao Y, Tonn K, Niazmand K, Fietzek UM, D'Angelo LT, Ceballos-Baumann a. e et al. "Online FOG Identification in Parkinson's disease with a time-frequency combined Algorithm." In: *Proc 2012 IEEE-EMBS Int Conf Biomed Heal Informatics*. (2012), pp. 192–195.

Acronyms

FI	Freezing Index
MEMS	MicroElectroMechanical Systems
PSD	Power Spectral Density
FB	Freezing Band
WB	Walking Band
EMG	Elettromiografia
EEG	Elettroencefalogramma
FTH	Freezing Threshold
FP	False Positive
PI	Power Index
PT	Power Threshold
MBFA	Moore-Bächlin FoG Algorithm
PD	Parkinson's disease