
University of Verona
Department of Computer Science
Master Degree in Computer Science and Engineering

Automatic detection of Freezing of Gait in patients with Parkinson's Disease

Candidate
Fuser Alessandro

Supervisor
Graziano Pravadelli

Assistant Supervisor
Florenc Demrozi

Degree Session of 20 March 2018
Academic year 2016/2017

Abstract

Acknowledgements

Contents

Acknowledgements	v
1 Introduction	1
1.1 Thesis Contribution	1
1.2 Outline	1
2 Letteratura	3
3 Background	7
4 Motivations and Goals	9
5 Self-adaptive TLM model	11
6 Software Implementation	13
7 Case Studies	15
8 Conclusions and Future Work	17
Bibliography	19

List of Figures

Introduction

Thesis Contribution

In this thesis, we have developed a methodology

Outline

The rest of the thesis is organized as follows: Chapter 2

Letteratura

Il problema del FOG è stato analizzato tramite una grande varietà di sistemi e sensori. Alcuni di questi, però, non sono utilizzabili durante la vita quotidiana dei pazienti poiché posso essere disponibili solo in ambienti di laboratorio. Esempi di questi sistemi sono le piattaforme di pressione[17], le quali sono non portatili, l'elettromiografia (EMG)[6], l'elettroencefalogramma (EEG)[20] o la conduttanza della pelle[22], il quale comporta il pizzamento di elettrodi sulla pelle in aggiunta ad sistema di rilevamento per raccogliere i dati. Altri sistemi invasivi sono i goniometri a ginocchio[1] o sistemi che fanno uso di camere e video, i quali hanno una bassa tolleranza del paziente in un'ambiente che non sia di laboratorio[1, 2, 5]. Quindi, dato che il monitoraggio del PD dovrebbe essere deambulatorio e durare diverse ore al fine di ricavare utili informazioni cliniche[9, 4], la maggior parte dei lavori si è basata su sistemi non invasivi come i dispositivi indossabili basati su circuiti microelettromeccanici (MEMS).

Nel 2003, Han et al. hanno usato MEMS basati su sistemi inerziali, come gli accelerometri, per esplorare le caratteristiche collegate agli episodi di FoG. Hanno trovato che la frequenza di risposta nei pazienti che indossavano gli accelerometri nella caviglia era intorno ai 6-8 Hz[16]. Nel 2008, Moore et al. hanno proposto una metodologia per identificare FoG con un'accelerometro posizionato nella caviglia nella quale hanno descritto il Freezing Index (FI), ossia il quoziente del rapporto della densità spettrale di potenza (PSD) tra 3 ed 8 Hz, chiamata Freezing Band (FB), con la PSD tra 0.5 e 3 Hz, denominata Walking Band (WB)[19]. Quando il FI supera una certa soglia (Freezing Threshold (FTH)), si considera che si sia verificato un episodio di FoG. A causa della presenza dei falsi positivi (FP) quando il paziente è a riposo, Bachlin et al. hanno introdotto il concetto di Power Index (PI), definito come la somma della WB e FB, il quale viene comparato con la Power Threshold (PTH) al fine di stabilire se c'era una quantità rilevante di movimento nel momento in cui il FI era alto, ossia oltre la soglia[19]. PI indica la quantità di movimento, perciò situazioni nelle quali il paziente non si stesse muovendo volontariamente sono state eliminate. In quest'ultima versione dell'algoritmo, quindi, un episodio di FoG è occorso se $FI > FTH$ e

PI>PTH. Questo metodo è il più avanzato nella detenzione di FoG dato il suo scarso costo computazionale e le sue buone performance[12].

L'algoritmo MBFA è stato ampiamente utilizzato nell'analisi del FoG, anche se di solito in condizioni di laboratorio e molto spesso con pochi pazienti. Jovanov et al. hanno implementato un algoritmo real time, anche se un solo volontario è stato usato per testare l'algoritmo. Inoltre, nessun risultato su sensibilità e specificità è stato riportato[12]. Zabaleta et al. hanno analizzato il FoG per mezzo di accelerometri a tre assi e giroscopi a due assi in differenti locazioni degli arti inferiori. La caratteristica principale ad essere stata analizzata è il FI in congiunzione con i cambiamenti della densità spettrale di potenza. Sono stati capaci di identificare correttamente l'82.7% degli episodi di FoG con i sensori inerziali posizionati su entrambe le caviglie, anche se in soli 2 pazienti[14].

Negli anni più recenti, Niazmand et al. (2011) hanno presentato il Mimed-Pants[18], pantaloni da jogging lavabili con 5 accelerometri integrati. Hanno usato MBFA per identificare FoG, ottenendo un 88.3% in sensibilità e 85.3% in specificità con 6 pazienti in brevi e controllati test focalizzati nell'indurre FoG senza tenere conto dei FP. Nel 2012, Zhao et al.[26] hanno sviluppato un algoritmo embedded basato sull'approccio MBFA all'interno del sistema Mimed-Pants ottenendo un 81% in sensibilità con 8 pazienti usando dei test simili ai precedenti. Più recentemente, Mazilu et al. hanno proposto un nuovo algoritmo online usando 3 accelerometri ed comparando diversi classificatori di machine learning che sfruttavano le caratteristiche del MBFA, aggiungendone di nuovo, in 10 pazienti[23]. I risultati ottenuti sono stati migliori del 95% per specificità e sensibilità con differenti classificatori. Questi test, però, sono stati condotti in situazioni di controllo ed, inoltre, la metodologia di validazione sovrastimava le prestazioni delle misure poichè i classificatori erano allenati, iterativamente, con tutte le finestre del segnale disponibili da un paziente escludendone una, la quale veniva usata per ottenere le prestazioni citate. Inoltre, le sequenze di allenamento e di test erano molto simili, il che è molto diverso da normali situazioni. Quindi, ci si aspetta che le riportate specificità e sensibilità calino drasticamente in situazioni non controllate.

Nel 2013, Moore et al. hanno pubblicato il più recente lavoro focalizzato sul MBA. In questo, hanno confrontato differenti configurazioni applicando lo stesso algoritmo in 25 pazienti, dei quali 20 hanno avuto episodi di FoG. Diverse finestre di segnale, posizionamento dei sensori e valori per PTH e FTH sono stati valutati al fine di trovare le condizioni ottimali. I risultati migliori sono stati ottenuti con le finestre di segnale più lunghe, anche se con queste Moore et al. hanno riportato una rilevante perdita di sensibilità negli episodi brevi che, paradossalmente, sono quelli più frequenti nei pazienti affetti da PD[24]. In un test più complesso eseguito precedentemente[25] usando fino a 7 sensori ed un protocollo di test più lungo, sono stati ottenuti una sensibilità e specificità sopra al 70%, anche se, in certe configurazioni (finestra di segnale pari a 7.5s e il sistema installato nella zona lombare), sia

per la sensibilità che la specificità hanno raggiunto valori oltre l'80%. In un approccio differente, Tripoli et al. hanno testato diverse configurazioni e locazioni dei sensori al fine di trovare la migliore configurazione[13]. Il lavoro è stato svolto con 5 pazienti ed in condizioni controllate, usando uno specifico protocollo progettato per stimolare il FoG e senza test di FP. In tale lavoro, hanno integrato 2 giroscopi oltre a 6 accelerometri posizionati in posizioni differenti del corpo. Con tutti i sensori indossati, è stata ottenuta un'accuratezza del 96.11%, una specificità del 98.74% e, eseguendo i test su tutti i pazienti tranne uno, una sensibilità dell'81.94%. D'altra parte, con una IMU singola nella zona lombare hanno riportato una sensibilità del 75% ed una specificità del 95%, anche se l'algoritmo non è stato confrontato con nessun altro metodo usato sotto le stesse condizioni.

In un più recente studio dal gruppo di Mazilu, hanno investigato un approccio di apprendimento non supervisionato per costruire un input ottimale per un classificatore ad albero di decisione con il dataset del progetto DAPHNET (10 pazienti PD). Il loro approccio è stato comparato ad un analogo basato su MBFA nel quale il FI e l'energia della banda spettrale tra 0.5 Hz e 8 Hz sono state valutate. L'allenamento ed i test erano dipendenti dall'utilizzatore e sotto condizioni controllate. I risultati superano l'approccio MBFA similare dell'8.1% in termini di punteggio dell'F1. Un altro approccio è stato presentato da Rodriguez et al., i quali hanno proposto un metodo per contestualizzare gli episodi di FoG tramite un algoritmo di riconoscimento dell'attività, il quale rifiutava i FP quando il paziente era seduto o eseguiva attività quali disegnare o digitare in un laptop. La specificità è stata aumentata in media del 5%, arrivando anche ad un 11.9% in certi casi[10]. Il metodo che aggiungeva la contestualizzazione, però, non ha contribuito a migliorare la sensibilità. Altri studi hanno la variabilità della camminata tra un episodio di FoG e condizioni normal. Anche se i risultati sono interessanti, hanno fallito nell'includere i falsi positivi ed un'affidabile classificazione non è stata eseguita[8, 3]. Un paper recente di Zach et al. presenta una nuova metodologia per suscitare FoG in condizioni di laboratorio controllate, le quali sono state valutate con l'algoritmo MBFA ottenendo una sensibilità del 75% ed una specificità del 76%[15].

Infine, Alrichs et al., all'interno del progetto REMARK[21], usano una Support Vector Machines (SVM) per rilevare episodi di FoG in 8 pazienti con PD in ambiente casalingo. Il metodo include test in differenti test motori usando un singolo accelerometro nella zona lombare, raggiungendo un'accuratezza del 90%. La specificità, però, è stata calcolata solo su pazienti non FoG, il che può portare a predizioni non affidabili in quanto il modello non è stato testato con pazienti PD con FoG, i quali hanno movimenti molto diversi dai pazienti che non soffrono di FoG. Inoltre, la valutazione è stata eseguita su finestre di un minuto, tempo che è considerato troppo lungo per un'implementazione online[7]. Sempre all'interno del progetto REMARK, Rodriguez et al. hanno presentato un lavoro che utilizza un algoritmo per

rilevare FoG tramite un approccio di machine learning basato su SVM ed un singolo accelerometro a 3 assi indossato nella zona lombare[11]. Il metodo è stato valutato su 21 pazienti affetti da PD in ambienti casalinghi sotto due condizioni: un modello generico testato su tutti i pazienti tranne uno ed un secondo modello personalizzato sull'utente che usa parte del dataset del paziente stesso. I risultati mostrano un significativo vantaggio del modello personalizzato rispetto a quello generico, portando ad un miglioramento in media, sia della sensibilità che della specificità, del 7.2%. Inoltre, l'approccio adottato è stato comparato con i metodi più utilizzati per la detenzione del FoG basati sull'algoritmo MBFA. I risultati del metodo generico mostrano un miglioramento in media dell'11.2% rispetto a metodi MBFA generici, mentre quello personalizzato porta ad un miglioramento del 10% rispetto ad altri metodi specifici sul paziente.

Background

Motivations and Goals

Chapter 5

Automatic generation of a self-adaptive TLM model

qui ci va la spiegaxione del tuo lavoro

Chapter 6

Software Implementation of the proposed methodology

qui invece ci puoi mettere a livello implementativo il tuo lavoro

Case Studies

Conclusions and Future Work

This thesis proposes a methodology

Bibliography

References

- [1] Delval A, Snijders AH, Weerdesteyn V, Duysens JE, Defebvre L, Giladi N, and et al. “Objective detection of subtle freezing of gait episodes in Parkinson’s disease.” In: *Mov Disord.* (2010), 25: 1684–1693.
- [2] Nieuwboer A, De Weerd W, Desloovere K, Fieuws S, and Broens kaucsik E. “Abnormalities of the Spatiotemporal Characteristics of Gait at the Onset of Freezing in Parkinson ‘ s Disease.” In: *Mov Disord.* (2001), 16: 1066–1075.
- [3] Tay A, Yen SC, Lee PY, Wang CY, Neo A, Phan SW, and et al. “Freezing of Gait (FoG) detection for Parkinson Disease.” In: *10th Asian Control Conference (ASCC)* (2015), pp. 1–6.
- [4] Weiss A, Herman T, Giladi N, and Hausdorff JM. “Objective assessment of fall risk in Parkinson’s disease using a body-fixed sensor worn for 3 days.” In: *PLoS One* (2014).
- [5] Takač B, Català A, Rodriguez Martin D, van der Aa N, Chen W, and Rauterberg M. “Position and Orientation Tracking in a Ubiquitous Monitoring System for Parkinson Disease Patients With Freezing of Gait Symptom.” In: *JMIR mhealth uhealth* (2013), 1: e14.
- [6] Cole BT, Roy SH, and Nawab SH. “Detecting Freezing-of-Gait During Unscripted and UNconstrained Activity”. In: *33rd Annual International Conference of the IEEE EMBS* (2011), pp. 5649–5652.
- [7] Ahlrichs C, Samà A, Lawo M, Cabestany J, Rodriguez-Martin D, Pérez-López C, and et al. “Detecting freezing of gait with a tri-axial accelerometer in Parkinson’s disease patients.” In: *Med Biol Eng Comput.* (2016), 54: 223–233.
- [8] Coste C, Sijobert B, Pissard-Gibollet R, Pasquier M, Espiau B, and Geny C. “Detection of Freezing of Gait in Parkinson Disease: Preliminary Results.” In: *Sensors* (2014), 14: 6819–6827.

- [9] Pérez-López C, Samà A, Rodriguez-Martin D, Català A, Cabestany J, and et al. de Mingo E. "Monitoring Motor Fluctuations in Parkinson's Disease Using a Waist-Worn Inertial Sensor." In: *International Work Conference on Artificial Neural Networks Advances in Computational Intelligence Lecture Notes on Computer Science*. (2015), pp. 461–474.
- [10] Rodriguez-Martin D, Samà A, Pérez-López C, Català A, Cabestany J, and Rodriguez-Molinero A. "A. Posture Detection with waist-worn Accelerometer : An application to improve Freezing of Gait detection in Parkinson ' s disease patients." In: *European Conference on Ambient Assisted Living*. (2014), pp. 1–6.
- [11] Rodriguez-Martin D, Samà A, Pérez López C, Català A, Moreno Arostegui JM, Cabestany J, and et al. "Home detection of freezing of gait using support vector machines through a single waist-worn triaxial accelerometer". In: *PLoS ONE* (2017).
- [12] Jovanov E, Wang E, Verhagen L, Fredrickson M, and Fratangelo R. "deFOG: A real time system for detection and unfreezing of gait of Parkinson's patients." In: *31st Annual International Conference of the IEEE EMBS*. (2009), pp. 5151–5154.
- [13] Tripoliti EE, Tzallas AT, Tsipouras MG, Rigas G, Bougia P, Leontiou M, and et al. "Automatic detection of freezing of gait events in patients with Parkinson's disease." In: *Comput Methods Programs Biomed. Elsevier Ireland Ltd* (2013), 110: 12–26.
- [14] Zabaleta H, Keller T, and Fimbel EJ. "Gait analysis in frequency domain for freezing detection in patients with Parkinson's disease." In: *Gerontechnology*. (2008).
- [15] Zach H, Janssen AM, Snijders AH, Delval A, Ferraye MU, Auff E, and et al. "Identifying freezing of gait in Parkinson's disease during freezing provoking tasks using waist-mounted accelerometry." In: *Parkinsonism Relat Disord. Elsevier Ltd* (2015), 21: 1362–1366.
- [16] Han JH, Lee WJ, Tae Beom A, Beom Suk J, and Kwang Suk P. "Gait analysis for freezing detection in patients with movement disorder using three dimensional acceleration system." In: *25th Annual International Conference of the IEEE EMBS*. (2003), pp. 1863–1865.
- [17] Hausdorff JM, Balash Y, and Giladi N. "Time series analysis of leg movements during freezing of gait in Parkinson's disease:akinesia,rhyme or reason?" In: *Physica A*. (2003), 321:656–570.
- [18] Niazmand K, Tonn K, Zhao Y, Fietzek UM, Schroeteler F, Ziegler K, and et al. "Freezing of Gait detection in Parkinson's disease using accelerometer based smart clothes." In: *IEEE Biomedical Circuits and Systems Conference (BioCAS)*. (2011), pp. 201–204.

- [19] Bachlin M, Roggen D, Plotnik M, Hausdorff JM, Giladi N, and Troster G. "Online Detection of Freezing of Gait in Parkinson's Disease Patients: A Performance Characterization." In: *Proc 4th Int ICST Conf Body Area, Networks*. (2009).
- [20] Handojoseno a MA, Shine JM, Nguyen TN, Tran Y, Lewis SJG, and Nguyen HT. "The detection of Freezing of Gait in Parkinson's disease patients using EEG signals based on Wavelet decomposition". In: *34th AnnuInt Conf IEEE Eng Med Biol Soc*. (2012), 2012:69–72.
- [21] REMPARK. "Personal Health Device for the Remote and Autonomous Management of Parkinson's Disease." In: *FP7-ICT-2011-7-287677*. (2011-2014).
- [22] Mazilu S, Calatroni A, Gazit E, Mirelman A, Hausdorff J, and Troester G. "Prediction of Freezing of Gait in Parkinson's from Physiological Wearables: An Exploratory Study." In: *IEEE J Biomed Heal Informatics*. (2015), 6:1–1.
- [23] Mazilu S, Hardegger M, Zhu Z, Roggen D, Troster G, Plotnik M, and et al. "Online Detection of Freezing of Gait with Smartphones and Machine Learning Techniques." In: *Proc 6th Int ICST Conf Pervasive Comput Technol Healthc*. (2012), pp. 123–130.
- [24] Moore ST, Yungher Da, Morris TR, Dilda V, MacDougall HGa, Shine JM, and et al. "Autonomous identification of freezing of gait in Parkinson's disease from lower-body segmental accelerometry". In: *Neuroeng Rehabil. Journal of NeuroEngineering and Rehabilitation* (2013).
- [25] Moore ST, MacDougall HG, and Ondo WG. "Ambulatory monitoring of freezing of gait in Parkinson's disease". In: *J Neurosci Methods* (2008), 167: 340–348.
- [26] Zhao Y, Tonn K, Niazmand K, Fietzek UM, D'Angelo LT, Ceballos-Baumann a., and et al. "Online FOG Identification in Parkinson's disease with a time-frequency combined Algorithm." In: *Proc 2012 IEEE-EMBS Int Conf Biomed Heal Informatics*. (2012), pp. 192–195.

Acronyms

FI	Freezing Index
MEMS	MicroElectroMechanical Systems
PSD	Power Spectral Density
FB	Freezing Band
WB	Walking Band
EMG	Elettromiografia
EEG	Elettroencefalogramma
FTH	Freezing Threshold
FP	False Positive
PI	Power Index
PT	Power Threshold
MBFA	Moore-Bächlin FoG Algorithm
PD	Parkinson's disease